

1 LC-Rec 多数据集基线对比

Dataset	Metrics	Caser	HGN	GRU4Rec	BERT4Rec	SASRec	FMLP-Rec	FDSA	S ³ -Rec	P5-CID	TIGER	LC-Rec	Improv.
Instruments	HR@1	0.0149	0.0523	0.0571	0.0435	0.0503	0.0480	0.0520	0.0367	0.0587	<u>0.0608</u>	0.0706	+16.12%
	HR@5	0.0543	0.0813	0.0821	0.0671	0.0751	0.0786	0.0834	<u>0.0863</u>	0.0827	<u>0.0863</u>	0.1002	+16.11%
	HR@10	0.0710	0.1048	0.1031	0.0822	0.0947	0.0988	0.1046	<u>0.1136</u>	0.1016	0.1064	0.1220	+7.39%
	NDCG@5	0.0355	0.0668	0.0698	0.0560	0.0627	0.0638	0.0681	0.0626	0.0708	<u>0.0738</u>	0.0856	+15.99%
	NDCG@10	0.0409	0.0744	0.0765	0.0608	0.0690	0.0704	0.0750	0.0714	0.0768	<u>0.0803</u>	0.0926	+15.32%
Arts	HR@1	0.0138	0.0300	0.0421	0.0337	0.0225	0.0310	0.0451	0.0245	<u>0.0485</u>	0.0465	0.0634	+30.72%
	HR@5	0.0379	0.0622	0.0749	0.0559	0.0757	0.0757	0.0734	0.0767	0.0724	<u>0.0788</u>	0.1011	+28.30%
	HR@10	0.0541	0.0875	0.0964	0.0713	0.1016	0.1046	0.0933	<u>0.1051</u>	0.0902	0.1012	0.1266	+20.46%
	NDCG@5	0.0262	0.0462	0.0590	0.0451	0.0508	0.0541	0.0595	0.0521	0.0607	<u>0.0631</u>	0.0828	+31.22%
	NDCG@10	0.0313	0.0544	0.0659	0.0500	0.0592	0.0634	0.0660	0.0612	0.0664	<u>0.0703</u>	0.0906	+28.88%
Games	HR@1	0.0085	0.0154	0.0176	0.0136	0.0145	0.0152	0.0161	0.0119	0.0177	<u>0.0188</u>	0.0317	+68.62%
	HR@5	0.0367	0.0517	0.0586	0.0482	0.0581	0.0571	<u>0.0644</u>	0.0606	0.0506	0.0599	0.0800	+24.22%
	HR@10	0.0617	0.0856	0.0964	0.0763	0.0940	0.0930	<u>0.1041</u>	0.1002	0.0803	0.0939	0.1174	+12.78%
	NDCG@5	0.0227	0.0333	0.0381	0.0311	0.0365	0.0361	<u>0.0404</u>	0.0364	0.0342	0.0392	0.0560	+38.61%
	NDCG@10	0.0307	0.0442	0.0502	0.0401	0.0481	0.0476	<u>0.0531</u>	0.0491	0.0437	0.0501	0.0681	+28.25%

表 1: LC-Rec 与现有 baseline 在 Instruments、Arts、Games 上的主表对比。加粗表示 LC-Rec，带下划线表示该行最强 baseline；若出现并列，则同时标出。

1.1 当前 SFT 复现实测

Dataset	Variant	Checkpoint	HR@1	HR@5	HR@10	NDCG@5	NDCG@10	NDCG@50	HR@50
Instruments	Paper LC-Rec	–	0.0706	0.1002	0.1220	0.0856	0.0926	–	–
Instruments	GenRec eval (best)	ckpt-4023	0.0647	0.0886	0.1084	0.0768	0.0832	0.0995	0.1836
Instruments	GenRec eval (late)	ckpt-5364	0.0629	0.0835	0.1012	0.0736	0.0793	0.0935	0.1671
Arts	Paper LC-Rec	–	0.0634	0.1011	0.1266	0.0828	0.0906	–	–
Arts	GenRec eval (best)	ckpt-8634	0.0533	0.0811	0.0996	0.0675	0.0734	0.0890	0.1709
Games	Paper LC-Rec	–	0.0317	0.0800	0.1174	0.0560	0.0681	–	–
Games	GenRec eval (best)	ckpt-14904	0.0232	0.0625	0.0945	0.0429	0.0532	0.0798	0.2166

表 2: 当前 LC-Rec/GenRec 相关 SFT 模型在 GenRec 统一评测口径下的复现实测。Arts 与 Games 取当前已同步 checkpoint 中的最佳结果。

1.2 Instruments 上的 rule-only RL 复现实测

Variant	Checkpoint	HR@1	HR@5	HR@10	NDCG@5	NDCG@10	NDCG@50	HR@50
Paper LC-Rec	–	0.0706	0.1002	0.1220	0.0856	0.0926	–	–
GenRec SFT (best)	ckpt-4023	0.0647	0.0886	0.1084	0.0768	0.0832	0.0995	0.1836
GenRec rule-only RL	ckpt-5006	0.0676	0.0922	0.1069	0.0802	0.0849	0.0964	0.1594

表 3: 当前 ins-lc4023-rule 在 GenRec 统一评测口径下的最佳 checkpoint，对比 Instruments SFT 复现与论文 LC-Rec 主表。

LC-Rec 包含多种语义对齐任务，具体包括：

- SEQ: Section III-C1 中介绍的序列物品预测任务，也是其主要目标。
- MUT: Section III-C2 中用于显式 index-language 对齐的双向预测任务。
- ASY: Section III-C3a 中的非对称物品预测任务。
- ITE: Section III-C3b 中基于用户意图的物品预测任务。
- PER: Section III-C3c 中的个性化偏好推断任务。

其中，后面三项都属于 Section III-C3 里提出的隐式、面向推荐的对齐任务。为了验证各个组成部分的有效性，论文在 Arts 和 Games 数据集上做了消融实验，用来分析每一部分的贡献。Table IV 的结果表明：在只包含协同语义的序列推荐基础上，逐步加入多种语义对齐任务，可以显著提升性能。LC-Rec 中这些 instruction tuning 任务整体上都对增强序列推荐有帮助，并且继续加入更多语义对齐任务，理论上仍有进一步提升空间。

1.3 基于 Table IV 的粗略推断

如果先不考虑 prompt 模板和 load_best_model_at_end 的影响，只把当前差距近似归因于“缺少 ITE 与 PER 两类任务”，那么可以直接用论文 Table IV 在 Arts 和 Games 上的增益来做一个数量级估计。

- Arts 上，从 +ASY 到最终 +PER，增幅大约是：HR@1 +5.32%，HR@5 +6.98%，HR@10 +8.01%，NDCG@5 +6.70%，NDCG@10 +6.84%。
- Games 上，从 +ASY 到最终 +PER，增幅大约是：HR@1 +12.81%，HR@5 +10.34%，HR@10 +9.41%，NDCG@5 +10.67%，NDCG@10 +10.73%。
- 取 Arts 和 Games 的平均值，少掉 ITE+PER 这两类任务，粗略可以理解成会带来约 HR@1 9.1%，HR@5 8.7%，HR@10 8.7%，NDCG@5 8.7%，NDCG@10 8.8% 的相对损失量级。
- 如果把这个量级反推到 Instruments 论文主表，意味着单看“缺少 ITE+PER”这一项，Instruments 上大致可能会损失：HR@1 约 0.0064，HR@5 约 0.0087，HR@10 约 0.0106，NDCG@5 约 0.0075，NDCG@10 约 0.0081。
- 按这个粗略推算，若从论文 Instruments 主表数值往下扣，落点大约会到：HR@1 0.0642，HR@5 0.0915，HR@10 0.1114，NDCG@5 0.0781，NDCG@10 0.0845。
- 这组反推值和当前复现实测 best checkpoint (HR@1=0.0647, HR@5=0.0886, HR@10=0.1084, NDCG@5=0.0768, NDCG@10=0.0832) 在量级上已经比较接近，因此如果接受“当前训练集基本等于 SEQ+MUT+ASY，主要少的是 ITE+PER”这个前提，那么现在这批 Instruments 结果偏低，确实大体可以由缺少这两类任务来解释。