

GenRec RL 实验整理：Instruments 主报告与 Games 附录

按实验主题重构的 LaTeX 研究稿

2026-04-26

摘要

本文把 Instruments-grec 上已经跑出来的主要 RL 实验按“baseline、canonical hint family、家族内部对照、专项消融”四层结构重排。正文仍以 Instruments 为主，默认将 dynamic gather-fix 视为正确的 canonical dynamic 实现，将 old fixed-hint 明确标成带 bug caveat 的历史参考，并把 max1、CE scaling、single-hint mixed 与 dual-task 这些后续探索拆成单独 section。本轮更新进一步把新同步回来的 dynamic hint + CE(0.005) 与 dynamic single-hint mixed 的更长轨迹接进同一份研究稿中，并把 fixed single-hint mixed + CE(0.005) 从旧的 first-look 升级成完整轨迹对照。当前完整曲线表明，这条新 fixed 变体并没有把 plain single-hint mixed 与 hintce-3 的优势叠加起来：它的 top-10 接近 parent line，但 coverage 明显更弱，因此暂时更像一次有信息量的负结果。附录则补入 Games-grec 的全流程摘要与 RL 结果，作为第二数据集上的交叉验证。

目录

1 Instruments 数据集实验范围	5
1.1 本文只讨论什么	5
1.2 共享实验背景	5
1.3 关于结果来源的说明	5
1.4 本文的默认约定	5
1.5 按什么顺序读	6
2 主表与 Baseline	6
2.1 主表：Instruments 上当前最重要的 run 地图	6
2.2 SFT 与 rule-only: baseline 在哪里	8
2.3 Canonical dynamic 与 fixed hint: 主线大方向	8
3 Dynamic Sid-Only vs Dynamic Gather-Fix	9
3.1 区别是什么	9
3.2 对应脚本	9
3.3 关键指标	9
3.4 图表	10
3.5 结论	10

目录	2
4 Fixed Sid-Only vs Fixed Taskfix	10
4.1 区别是什么	10
4.2 对应脚本	11
4.3 关键指标	11
4.4 图表	11
4.5 结论	12
5 Ranking Dynamic vs Canonical Dynamic	12
5.1 区别是什么	12
5.2 对应脚本	12
5.3 关键指标	12
5.4 图表	13
5.5 结论	13
6 错版 Fixed vs Corrected Fixed	13
6.1 对应脚本	13
6.2 对应曲线图	14
6.3 Bug 图	15
6.4 任务级摘要	15
6.5 结论	15
7 Max1 消融	16
7.1 实验问题	16
7.2 对应脚本	16
7.3 改动范围	16
7.4 关键指标	16
7.5 图表	17
7.6 结论	18
8 CE Scaling 消融	18
8.1 fixed CE family 与 dynamic CE trajectory	18
8.2 对应脚本	19
8.3 关键指标	19
8.4 图表	20
8.5 结论	21
9 Single-Hint Mixed 消融	22
9.1 实验定义	22
9.2 对应脚本	22
9.3 关键指标	23
9.4 图表	24
9.5 结论	25

目录	3
10 Single-Hint Mixed + CE(0.005) 完整轨迹	26
10.1 实验定义	26
10.2 对应脚本	26
10.3 关键指标	26
10.4 图表	27
10.5 结论	27
11 Dual-Task 消融	28
11.1 实验定义	28
11.2 对应脚本	28
11.3 关键指标	28
11.4 图表	29
11.5 结论	30
12 Instruments 最有潜力候选总览	30
12.1 为什么单独抽这一组	30
12.2 最好点摘要	31
12.3 NDCG@10	32
12.4 HR@10	32
12.5 NDCG@50	33
12.6 HR@50	33
12.7 怎么读这一组图	33
13 Hint-Token SFT: 去掉 RL 后的 Beam-Selected Hint Imitation	34
13.1 动机	34
13.2 代码入口	34
13.3 Fixed 版本	34
13.4 Dynamic 版本	35
13.5 Loss 细节	35
13.6 和之前 CE / RL 的区别	35
13.7 学习率与 coef	36
13.8 当前验证状态	36
14 结论与下一步	36
14.1 当前最稳的主故事	36
14.2 下一步最值得继续补的证据	37
14.3 Games 当前定位	37
A Games-grec 全流程摘要	37
A.1 为什么把 Games 放进附录	37
A.2 Index 与下游数据	38
A.3 SFT checkpoint 选择	38

B Games-grec RL 结果	39
B.1 对应 launcher	39
B.2 最好点与 coverage 峰值	40
B.3 RL 曲线图	41
B.4 最好点 trade-off	42
B.5 当前读法	42

1 Instruments 数据集实验范围

1.1 本文只讨论什么

这份整理稿只讨论 Instruments-grec 数据集上的 RL 实验, 不把 Games、跨数据集 sweep、reward form 的完整历史演化和更早期的 exploratory runs 一起混进来。当前主线关注的是:

- SFT 与 plain rule-only baseline 的位置
- canonical dynamic hint 与 fixed hint family 的相对位置
- dynamic / fixed 家族内部几个关键变体的对照
- 后续几条最值得继续追的消融与扩展: max1、CE scaling、single-hint mixed、dual-task

1.2 共享实验背景

- 数据集: Instruments-grec
- RL 起点: Instruments-grec-sft-qwen4B-4-256-dsz0/checkpoint-495
- Instruments 主线 launcher 目录: hope/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec/
- 主读法: 默认先看 best NDCG@10, 再看对应的 HR@50 和必要时的 peak HR@50
- 进度轴: 不同 run 的完整 step horizon 不总相同, 因此图里统一转成 epoch 时, 需要显式写清楚归一化口径

1.3 关于结果来源的说明

本文主表和曲线统一读取本地同步回来的 checkpoint 指标文件: 主要来源是各实验目录下的 checkpoint-*/metrics.json, 以及 SFT 参考线对应的 checkpoint-495/metrics.json。报告里不再附外部平台链接, 只保留 model_dir、launcher 路径和本地导出的对比表。

1.4 本文的默认约定

1. dynamic gather-fix 被视为当前正确的 canonical dynamic 实现; 后文里如果直接写“dynamic”, 默认指它。
2. old fixed hint mixed-single 只作为带 bug caveat 的历史参考线, 不再把它当作方法定义本身。
3. corrected fixed taskfix sid-only 被当作当前更干净的 fixed 参考线。

1.5 按什么顺序读

章节	作用	当前内容
主表与 baseline	建立全局地图	Instruments 上的主表、SFT 与 rule-only baseline、canonical dynamic 与 fixed 的位置
Hint 家族内部对照	看清关键 family 差异	dynamic sid-only、ranking dynamic、fixed sid-only, 以及 old fixed bug 对 corrected fixed 的影响
专项消融与新探索	跟后续值得继续追的方向	max1、CE scaling、single-hint mixed、dual-task

2 主表与 Baseline

2.1 主表: Instruments 上当前最重要的 run 地图

Group	Variant	Best ckpt	Epoch	NDCG@10	HR@50
Baseline	SFT495	checkpoint-495	–	0.0823	0.1844
Baseline	rule-only rerun	checkpoint-2997	1.802	0.0960	0.1681
Dynamic	dynamic gather-fix	checkpoint-2997	1.802	0.0936	0.1855
Dynamic	dynamic sid-only	checkpoint-2394	1.805	0.0921	0.1830
Dynamic	ranking dynamic	checkpoint-1665	1.001	0.0911	0.1822
Fixed	fixed taskfix	checkpoint-2997	1.802	0.0931	0.1941
Fixed	fixed taskfix sid-only	checkpoint-2652	2.000	0.0945	0.1935
Historical	old fixed mixed-single	checkpoint-3326	2.000	0.0953	0.1938
Ablation	dynamic max1	checkpoint-1332	0.801	0.0934	0.1905
CE	hintce-2	checkpoint-2664	1.602	0.0931	0.1951
CE	hintce-3	checkpoint-1665	1.001	0.0945	0.1985
Hint ablation	single-hint mixed	checkpoint-2664	1.602	0.0948	0.1958
Dual-task	dynamic dual-task	checkpoint-1510	1.003	0.0930	0.1885
Dual-task	fixed dual-task	checkpoint-2718	1.805	0.0939	0.1897

表 1: Instruments 数据集上的主线 run 地图。




图 1: 主线七线曲线图, 用来给后续 section 定位。




图 2: best NDCG@10 对应的 top-10 / coverage trade-off。

先看这张主表, 最重要的定位只有三点:

1. plain rule-only 仍然是 top-10 最强 baseline, 但 coverage 明显最差。

2. `dynamic gather-fix` 是后文默认使用的 canonical dynamic。
3. `clean fixed family`、`single-hint mixed`、`hintce-3` 和 `fixed dual-task` 都落在图里的更右上区域，因此它们是后文重点解释的对象。

2.2 SFT 与 rule-only: baseline 在哪里

对应脚本

- 脚本目录: `hope/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec/`
- `rule-only: Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only.sh`

Variant	Best ckpt	NDCG@10	HR@10	NDCG@50	HR@50
SFT495	checkpoint-495	0.0823	0.1094	0.0985	0.1844
rule-only rerun	checkpoint-2997	0.0960	0.1179	0.1070	0.1681

表 2: SFT 与 plain rule-only baseline。

这一组 baseline 的读法很清楚：

- `rule-only` 相比 SFT，把 NDCG@10 从 0.0823 拉到 0.0960，说明 exact reward 确实能把 top-10 打高。
- 但它的 HR@50 从 0.1844 掉到 0.1681，说明 plain exact reward 仍然在用 coverage 换 headline top-10。

2.3 Canonical dynamic 与 fixed hint: 主线大方向

Variant	Best ckpt	NDCG@10	HR@10	NDCG@50	HR@50
rule-only rerun	checkpoint-2997	0.0960	0.1179	0.1070	0.1681
dynamic gather-fix	checkpoint-2997	0.0936	0.1169	0.1083	0.1855
fixed taskfix sid-only	checkpoint-2652	0.0945	0.1205	0.1103	0.1935

表 3: 主线故事可以先压缩成 baseline、canonical dynamic 和 clean fixed 三条线。

如果只想记住一张最核心的对照表，这张就够了：

- `rule-only` 提供最强的无 hint top-10 baseline。
- `dynamic gather-fix` 是“hint scaffold 有用”的干净证据，它把 coverage 拉回到了 SFT 以上。
- `clean fixed taskfix sid-only` 则进一步把 trade-off 推到了更右上方：相对 canonical dynamic，多了 0.0009 的 NDCG@10 和 0.0080 的 HR@50。

3 Dynamic Sid-Only vs Dynamic Gather-Fix

3.1 区别是什么

这两条线都属于 dynamic hint family，默认都用：

- `reward_mode=rule_only`
- `dynamic_hint_max_depth=3`
- 不在 eval 侧继续应用 dynamic hint

真正的差异主要有两点：

- `dynamic sid-only` 不是在 mixed RL 数据上只改一个 flag，而是直接切到了专门的 sid-only RL 数据变体：`Instruments_grec_rlsidonly_index_emb-...`
- `dynamic gather-fix` 则继续跑默认 mixed RL 数据变体：`Instruments_grec_index_emb-...`；在本文里，它也被视为当前 canonical dynamic 实现。

3.2 对应脚本

- 画图脚本：`docs/research/scripts/build_instruments_report_figures.py`
- 脚本目录：`hope/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec/`
- canonical dynamic：`Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-dynamic-hint.sh`
- dynamic sid-only：`Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-dynamic-hint-sid-only.sh`

3.3 关键指标

Variant	Best ckpt	Epoch	NDCG@10	HR@10	NDCG@50	HR@50
dynamic sid-only	checkpoint-2394	1.805	0.0921	0.1155	0.1065	0.1830
dynamic gather-fix	checkpoint-2997	1.802	0.0936	0.1169	0.1083	0.1855

表 4: dynamic sid-only 与 canonical dynamic gather-fix。

3.4 图表




图 3: dynamic sid-only vs canonical dynamic gather-fix。

3.5 结论

- dynamic sid-only 不是完全失败，但 peak 来得更早，后续没有继续抬高。
- dynamic gather-fix 四个主指标同时更强，因此应被视为当前默认的 dynamic 实现。

4 Fixed Sid-Only vs Fixed Taskfix

4.1 区别是什么

这两条线都属于 corrected fixed-hint family，但区别不是只改一个输出目录名：

- fixed taskfix 继续跑默认 mixed RL 数据变体，并复用当前 task-aware fixed-hint export 流程。
- fixed taskfix sid-only 则切到了专门的 sid-only RL 数据变体，并额外走了一条 sid-only beam hint 分析 / 导出流程；脚本里能看到独立的 ANALYSIS_RUN_NAME、ANALYZE_HINT_DEPTH=1 和 sid-only 对应的 summary/details 路径。

4.2 对应脚本

- 画图脚本: docs/research/scripts/build_instruments_report_figures.py
- 脚本目录: hope/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec/
- fixed taskfix: Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-fixed-hint.sh
- fixed sid-only: Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-fixed-hint-sid-only.sh
- old fixed: 当前 hope/ 树里没有单独保留 old mixed-single launcher; 这里只把它当历史结果线看。

4.3 关键指标

Variant	Best ckpt	Epoch	NDCG@10	HR@10	NDCG@50	HR@50
fixed taskfix	checkpoint-2997	1.802	0.0931	0.1189	0.1094	0.1941
fixed taskfix sid-only	checkpoint-2652	2.000	0.0945	0.1205	0.1103	0.1935
old fixed mixed-single	checkpoint-3326	2.000	0.0953	0.1193	0.1114	0.1938

表 5: fixed taskfix、fixed taskfix sid-only 与 old fixed 的位置。

4.4 图表



图 4: fixed sid-only 与 fixed taskfix 的对照图。

4.5 结论

- `fixed taskfix sid-only` 主要把 top-10 hit 又往上推了一步，因此它是更合适的 clean fixed reference。
- `fixed taskfix` 本身已经明显强于 `plain rule-only`，说明 task-aware 修复本身就在生效。
- old fixed 仍然可以当历史上界参考，但不应该继续当方法定义。

5 Ranking Dynamic vs Canonical Dynamic

5.1 区别是什么

这两条线的核心差异不是 hint 机制，而是 reward：

- canonical dynamic 用的是 `reward_mode=rule_only`。
- ranking dynamic 用的是 `reward_mode=ranking`。

除此之外，它们默认共享相同的数据变体、相同的 dynamic hint 深度上限和相同的训练大框架。因此这一节更像是在问：把 dynamic hint 套在 ranking reward 上，到底有没有比 canonical rule-only dynamic 更强。

5.2 对应脚本

- 画图脚本： `docs/research/scripts/build_instruments_report_figures.py`
- 脚本目录： `hope/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec/`
- ranking dynamic: `Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-ranking-dynamic-hint.sh`
- canonical dynamic: `Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-dynamic-hint.sh`

5.3 关键指标

Variant	Best ckpt	Epoch	NDCG@10	HR@10	NDCG@50	HR@50
ranking dynamic	checkpoint-1665	1.001	0.0911	0.1138	0.1058	0.1822
dynamic gather-fix	checkpoint-2997	1.802	0.0936	0.1169	0.1083	0.1855

表 6: ranking dynamic 与 canonical dynamic gather-fix。

5.4 图表




图 5: ranking dynamic vs canonical dynamic gather-fix。

5.5 结论

- 按 best NDCG@10 点比较, ranking dynamic 四指标同时落后于 dynamic gather-fix。
- 图上也能直接看到它更像“中期见顶, 后期失速”的 run, 而不是新的主线实现。

6 错版 Fixed vs Corrected Fixed

6.1 对应脚本

- 画图脚本: docs/research/scripts/build_instruments_report_figures.py
- 脚本目录: hope/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec/
- corrected fixed: Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-fixed-hint.sh
- corrected fixed sid-only: Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-fixed-hint-sid-only.sh
- old fixed: 当前 hope/ 树里没有独立 launcher 保留, 因此这里只把它当历史结果线看。

6.2 对应曲线图




图 6: old fixed vs corrected fixed family。

6.3 Bug 图




图 7: old fixed 的 bug 会把不同任务的 hint depth 分布系统性压歪。

6.4 任务级摘要

Task	Changed rate	Avg depth correct	Avg depth buggy	主效应
task1_sid_sft	7.64%	1.048	0.938	只被轻微压浅
task4_hisTitle2sid	82.35%	1.533	0.188	hardest task 几乎被压成 depth-0
task5_title_desc2sid	19.41%	0.519	0.245	一部分 depth-2 被压回 0/1

表 7: old fixed 的 bug 不是“hint 更准”，而是把任务分布系统性压浅。

6.5 结论

- old fixed 的表面优势，不是来自更正确的 hint map，而是因为 hardest task 被系统性少给 hint。
- 因此它更像一个带偏置的历史现象学上界，而不是应该继续复用的方法定义。
- 这也是为什么本文后文在需要 fixed reference 时，默认优先引用 corrected fixed taskfix sid-only。

7 Max1 消融

7.1 实验问题

这一组实验只改一件事：把 dynamic hint 的 online budget 从 `dynamic_hint_max_depth=3` 收紧到 1。因此它回答的问题也很集中：

如果只允许 dynamic hint 最多暴露 1 个 oracle token，而不改 trainer 逻辑、不丢 no-hit 样本，最终的 eval trade-off 会落在什么位置。

7.2 对应脚本

- 脚本目录：hope/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec/
- max1: Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-dynamic-hint-max1.sh

7.3 改动范围

维度	baseline	max1 实验	备注
reward mode	rule-only	rule-only	不变
num beams	16	16	不变
dataset variant	Instruments-grec 主线数据	相同	不变
trainer 收口逻辑	当前 dynamic trainer	相同	不变
样本筛选	不丢 no-hit 样本	不丢	不变
hint budget	max depth 3	max depth 1	唯一改动

表 8: max1 消融的唯一改动是 online hint budget。

7.4 关键指标

Variant	Best ckpt	Epoch	NDCG@10	HR@50
rule-only rerun	checkpoint-2997	1.802	0.0960	0.1681
dynamic gather-fix	checkpoint-2997	1.802	0.0936	0.1855
dynamic max1	checkpoint-1332	0.801	0.0934	0.1905
fixed taskfix sid-only	checkpoint-2652	2.000	0.0945	0.1935

表 9: max1 的位置：更像 early-stop dynamic candidate，而不是新的默认线。

7.5 图表




图 8: max1 ablation 曲线。




图 9: max1 与 dynamic/fixed 参考线的 four-way comparison。

7.6 结论

- max1 不是退化成 rule-only，因为它保住了明显更高的 coverage。
- 它也不是被 gather-fix 全程支配，因为早中段确实能给出更好的 trade-off。
- 但完整轨迹已经说明它的优势主要停在前中段，因此更准确的定位仍然是 early-stop 候选，而不是新的 long-run default。

8 CE Scaling 消融

8.1 fixed CE family 与 dynamic CE trajectory

fixed CE family 仍然是这节的主体，但现在这条 dynamic CE 线已经补到完整长跑，因此这里统一按“4 条 fixed CE + 1 条 dynamic CE”来读：

- hintce：早期版本，这里记作 batch-mean CE。
- hintce-2：和当前公式说明里 strict DAPO CE 更一致的 token-mean 版本。
- hintce-3：在 hintce-2 的基础上，把 CE 相对倍率调到 0.005。
- hintce-4：把 CE 相对倍率继续抬到 0.01 的更激进版本。

- `dynamic hint + CE(0.005)`: 在 `canonical dynamic gather-fix` 上额外挂 `prompt-side CE` 的新尝试; 当前已经同步到完整 `checkpoint-3326`。

8.2 对应脚本

- 画图脚本: `docs/research/scripts/build_instruments_report_figures.py`
- 脚本目录: `hope/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec/`
- fixed family launcher: `Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-fixed-hint-ce.sh`
- dynamic first-look launcher: `Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-dynamic-hint-ce.sh`

8.3 关键指标

Variant	Best ckpt	Epoch	NDCG@10	HR@50	备注
fixed taskfix	checkpoint-2997	1.802	0.0931	0.1941	non-CE 参考线
hintce	checkpoint-2664	1.602	0.0915	0.1944	batch-mean CE
hintce-2	checkpoint-2664	1.602	0.0931	0.1951	token-mean / 更符合 DAPO
hintce-3	checkpoint-1665	1.001	0.0945	0.1985	在 hintce-2 基础上把倍率调到 0.005
hintce-4	checkpoint-2997	1.802	0.0953	0.1943	0.01 倍率; 当前已同步到完整可比较后段
dynamic hint + CE(0.005)	checkpoint-1998	1.201	0.0917	0.1851	full-trace dynamic CE; peak HR@50 仍在 checkpoint-666

表 10: CE scaling 消融。

8.4 图表




图 10: 四条 fixed CE 线与 non-CE fixed baseline 的完整对照。




图 11: dynamic hint + CE 的完整轨迹；当前已同步到 `checkpoint-3326`。

8.5 结论

- full non-CE 仍然是当前 fixed family 的干净参考线。
- `hintce`、`hintce-2`、`hintce-3` 和 `hintce-4` 现在已经能放到同一张图里一起读，不再只讲单条 fixed CE 线。
- `hintce-2` 是当前更稳的 token-mean / DAPO-compatible CE 候选；`hintce-3` 则是在它基础上把倍率抬到 0.005 后得到的更激进版本。
- 当前 ‘0.01’ 倍率的 `hintce-4` 已经不再只是 early readout：它现在一路补到 ‘`checkpoint-2997`’，best NDCG@10 已经来到 ‘0.0953’，说明这条线不是“偏激后直接失效”，而是真正进入了可比前沿。
- 但按当前完整可见轨迹看，`hintce-4` 和 `hintce-3` 呈现的是不同形状：`hintce-4` 更像“把 top-10 往长跑尾段继续抬高”，而 `hintce-3` 仍然保留更高的 coverage 峰值 ‘0.1985’。因此现在更合理的说法不是“ce4 不行”，而是“它在 top-10 上已经追平 old fixed 历史上界，但还没有在 coverage 上超过 ce3”。
- `dynamic hint + CE(0.005)` 现在已经补到完整 `checkpoint-3326`。它的 best NDCG@10 点来到 `checkpoint-1998` / 0.0917，但对应 HR@50 只有 ‘0.1851’；而它的 peak HR@50 仍然停在更早的 `checkpoint-666` / 0.1910，后段逐步回落到尾点 ‘0.1839’。

- 因此当前更合理的判断已经不再是“需要继续等后段再看”，而是：这条 dynamic CE 线并没有超过 canonical dynamic gather-fix，也没有改写 dynamic family 排序。它更像一次有信息量的负结果，说明把 fixed-side prompt CE 直接搬到 dynamic gather-fix 上，当前并不会自然带来更好的长跑表现。

9 Single-Hint Mixed 消融

9.1 实验定义

这条线现在已经有 fixed / dynamic 两个版本，它们的共同点都不是“只训练 task1”，而是 mixed 三任务仍然一起训练，只把 hint 限制到 task1_sid_sft：

- fixed single-hint mixed：只对 task1_sid_sft 注入 fixed hint，其余任务继续按 zero-hint 路径走。
- dynamic single-hint mixed：只对 task1_sid_sft 开 dynamic cascade，其余任务被强制停在 stage-0 / no-hint 路径。

9.2 对应脚本

- 画图脚本：docs/research/scripts/build_instruments_report_figures.py
- 脚本目录：hope/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec/
- fixed launcher:Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-fixed-hint-sid-hint-only-mixed.sh
- dynamic launcher:Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-dynamic-hint-sid-hint-only.sh

9.3 关键指标

Variant	Best ckpt	Epoch	NDCG@10	HR@50	备注
fixed taskfix	checkpoint-2997	1.802	0.0931	0.1941	clean fixed 参考
fixed taskfix sid-only	checkpoint-2652	2.000	0.0945	0.1935	clean sid-only 上界
old fixed mixed-single	checkpoint-3326	2.000	0.0953	0.1938	带 bug caveat 的历史上界
fixed single-hint mixed	checkpoint-2664	1.602	0.0948	0.1958	当前最强 partial-hint 候选
dynamic dual-task	checkpoint-1510	1.003	0.0930	0.1885	当前 task-filtered dynamic 参考
dynamic single-hint mixed	checkpoint-2331	1.402	0.0911	0.1823	当前已同步到 checkpoint-2997, 但仍弱于 dynamic baseline

表 11: single-hint mixed 现在已经从 fixed-only 读法扩展到 fixed / dynamic 两个版本。

9.4 图表



图 12: single-hint mixed vs fixed family。




图 13: single-hint mixed vs dynamic family; 当前 compact 图里直接放入新的 dynamic single-hint mixed。

9.5 结论

- 这条线不再只是 fixed-only 实验; 现在已经能把 fixed / dynamic 两个“只对 task1 给 hint”的版本放到同一节里读。
- fixed single-hint mixed 仍然是当前更强、更完整的 partial-hint 候选: 它的 best 点已经同时超过 corrected fixed taskfix sid-only 的 NDCG@10 和 HR@50。
- dynamic single-hint mixed 现在已经补到 checkpoint-2997。它的 best NDCG@10 点在 checkpoint-2331 / 0.0911, 对应 HR@50=0.1823; peak HR@50 则出现在 checkpoint-1665 / 0.1874, 而尾点回落到 ‘0.0905 / 0.1802’。
- 这意味着之前在 checkpoint-666 看起来还算有希望的 early-window readout, 并没有沿着长跑继续长成一个真正的 dynamic 候选。按当前完整得多的轨迹看, 它既没有接近 fixed single-hint mixed, 也没有超过 canonical dynamic gather-fix 或 dynamic dual-task。
- 因而这条线现在更像“帮助理解 partial-hint 机制边界”的对照项, 而不是需要优先追加资源的新主候选。真正仍值得继续解释的 partial-hint 故事, 仍然主要发生在 fixed single-hint mixed 上。

10 Single-Hint Mixed + CE(0.005) 完整轨迹

10.1 实验定义

这条新线把前一节的 fixed single-hint mixed 和 CE scaling 里的 hintce-3 直接拼到一起：

- 训练任务仍然保持 mixed 三任务。
- hint 仍然只对 task1_sid_sft 打开，也就是沿用 single-hint mixed 的 partial-hint 设定。
- 同时在这个设定上再加 fixed-side prompt CE，倍率沿用 0.005，也就是和 hintce-3 相同的 CE 系数。

因此这里最自然的比较对象不是整个 fixed family，而是它的两个“父实验”：single-hint mixed 和 fixed CE coef=0.005 (hintce-3)。

10.2 对应脚本

- 画图脚本：docs/research/scripts/build_instruments_report_figures.py
- 脚本目录：hope/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec/
- plain single-hint mixed launcher:Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-fixed-hint-sid-sh
- single-hint mixed + CE(0.005) launcher:Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-fixed-hint-sh
- fixed CE coef=0.005 parent launcher:Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-fixed-hint-sh

10.3 关键指标

Variant	Best ckpt	Epoch	NDCG@10	HR@50	备注
fixed single-hint mixed	checkpoint-2664	1.602	0.0948	0.1958	plain partial-hint baseline
fixed CE coef=0.005 (hintce-3)	checkpoint-1665	1.001	0.0945	0.1985	plain CE parent line
single-hint mixed + CE(0.005)	checkpoint-2664	1.602	0.0943	0.1919	当前已同步到 checkpoint-3326

表 12: single-hint mixed + CE(0.005) 与两个 parent line 的完整轨迹对照。

10.4 图表




图 14: single-hint mixed + CE(0.005) vs plain single-hint mixed vs fixed CE coef=0.005。

10.5 结论

- 这条线现在虽然已经补齐到完整 `checkpoint-3326`，但按代码实现看，它并不是一个“把 `single-hint mixed` 和 `hintce-3` 直接做加法”的 clean additive ablation。
- 关键原因在于 task scope 被改了两次：这两个 `single-hint launcher` 都把 `FIXED_HINT_TASK_NAMES`、`ANALYSIS_TASK_NAMES` 和 `EVAL_TASK_NAMES` 固定成 `task1_sid_sft`，而 plain `hintce-3` 的 fixed-hint CE launcher 并没有这组 task filter。也就是说，`hintce-3` 是“full fixed-hint + CE”，而这里的新线实际上是“task1-only fixed-hint + task1-only CE”。
- 更具体地说，trainer 在应用 `fixed_hint_task_names` 时，会把不在集合里的样本直接改写成 zero-hint example，而不是保留成“有 map 但不显示 hint”的状态；随后 prompt-side CE mask 又直接由 `oracle_hint_depth` 构造。因此对 `task4/task5` 来说，新线不仅没有 fixed hint，也没有任何 hint CE 梯度；CE 实际上只作用在 `task1` 被显式拼进 prompt 的那几个 oracle prefix token 上。
- 这就是为什么这里的“叠加”更像副作用，而不是 gain source 的自然相加：它新增的不是一个覆盖整个 mixed-task training distribution 的辅助损失，而是一个只在 `task1`、只在已经暴露出来的 hinted prefix 上生效的额外正则。这个操作更接近于重新加重 `task1` 前

缀 token 的 imitation pressure，而不是把 hintce-3 的稳定化机制完整搬进 single-hint mixed。

- 从结果上看，这种 task-conditional reweighting 也确实没有长成新的主候选：新线 best 点是 checkpoint-2664 / NDCG@10=0.0943 / HR@50=0.1919, NDCG@10 只接近 hintce-3 的 0.0945，但仍低于 plain single-hint mixed 的 0.0948；而 HR@50 则同时明显低于两个 parent line 的 0.1958 和 0.1985。因此当前更合理的结论不是“继续等后段翻盘”，而是：这条线提供了一次有信息量的机制性负结果，说明 partial-hint task gating 和 prompt-side CE 在这个实现下并不会自动叠加成更好的 coverage-balanced candidate。

11 Dual-Task 消融

11.1 实验定义

这一组实验只保留 task1 + task5，因此要同时看 dynamic 与 fixed 两条 dual-task 线，并把它们放回 canonical dynamic 与 clean fixed reference 的上下文里读。

11.2 对应脚本

- 画图脚本：docs/research/scripts/build_instruments_report_figures.py
- 脚本目录：hope/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec/
- dynamic dual-task: Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-dynamic-hint-sid-title-desc.sh
- fixed dual-task: Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec-rl-rule-only-fixed-hint-sid-title-desc.sh

11.3 关键指标

Variant	Best ckpt	Epoch / aligned epoch	NDCG@10	HR@50
dynamic gather-fix	checkpoint-2997	1.802	0.0936	0.1855
dynamic dual-task	checkpoint-1510	1.003 / 1.861	0.0930	0.1885
fixed dual-task	checkpoint-2718	1.805 / 1.972	0.0939	0.1897
fixed taskfix sid-only	checkpoint-2652	2.000	0.0945	0.1935

表 13: dual-task family 与 canonical dynamic / clean fixed reference 的位置。

11.4 图表




图 15: fixed dual-task vs fixed family: old fixed、fixed sid-only、corrected fixed taskfix、fixed single-hint mixed。




图 16: dynamic dual-task vs dynamic baselines: canonical dynamic gather-fix、dynamic sid-only、rule-only、dynamic single-hint mixed。

11.5 结论

- 把 dual-task family 拆成 fixed / dynamic 两张图之后，fixed 侧更容易直接看出：fixed dual-task 仍落后于 old fixed、corrected fixed taskfix sid-only、corrected fixed taskfix 和 fixed single-hint mixed。
- dynamic 侧则更容易看出：dynamic dual-task 已经进入可比较状态，但当前仍没有超过 canonical dynamic gather-fix，也没有超过 rule-only、dynamic sid-only 或 dynamic single-hint mixed 这些 baseline。
- 因而当前更准确的定位仍然是：dual-task 是一条值得继续跟的 filtered setting，而不是已经改写主线排序。

12 Instruments 最有潜力候选总览

12.1 为什么单独抽这一组

如果只看当前最值得继续讲、继续扩、继续做 follow-up 的 Instruments 候选，最有代表性的不是全部 family，而是下面这几条：

- SFT495: 所有 RL 线的共同参考点。

- **rule-only rerun**: 当前最强的无 hint top-10 baseline。
- **single-hint mixed**: 当前最值得认真对待的新主候选。
- **old fixed mixed-single**: 带 bug caveat 的历史上界。
- **corrected fixed taskfix sid-only**: 当前最干净的 fixed reference。
- **corrected fixed taskfix**: coverage 很强的 clean fixed 变体。
- **hintce-3**: 当前最值得继续追的 CE scaling 候选。
- **hintce-4**: 当前把 top-10 继续往尾段抬高的 ‘0.01’ 倍率 CE 候选。

这一节不再把四个指标塞进一张 2x2 大图，而是每个指标单独出一张图。这样做的目的很直接：这几条线已经非常接近，拆成单指标之后更容易看清谁在 top-10 上领先，谁在 coverage 上更稳。

12.2 最好点摘要

Variant	Best ckpt	NDCG@10	HR@10	NDCG@50	HR@50
SFT495	checkpoint-495	0.0823	0.1094	0.0985	0.1844
rule-only rerun	checkpoint-2997	0.0960	0.1179	0.1070	0.1681
single-hint mixed	checkpoint-2664	0.0948	0.1180	0.1116	0.1958
old fixed mixed-single	checkpoint-3326	0.0953	0.1193	0.1114	0.1938
fixed taskfix sid-only	checkpoint-2652	0.0945	0.1205	0.1103	0.1935
fixed taskfix	checkpoint-2997	0.0931	0.1189	0.1094	0.1941
fixed CE coef=0.005	checkpoint-1665	0.0945	0.1180	0.1118	0.1985
fixed CE coef=0.01	checkpoint-2997	0.0953	0.1204	0.1113	0.1943

表 14: Instruments 当前最有潜力候选的最好点。

这张表最值得记住的不是单一冠军，而是当前候选的形状：

- **rule-only** 仍然是 top-10 最强的极值线，但 **HR@50** 明显最差。
- **single-hint mixed**、**old fixed**、**clean fixed family**、**hintce-3** 和 **hintce-4** 已经整体挤进了更右上的一团，因此这几条线才是真正应该继续互相比的“前沿集合”。
- **hintce-3** 当前 best 点的 **HR@50=0.1985** 最强，但它的 best 点更靠中段；**hintce-4** 则把 top-10 一路抬到了 **checkpoint-2997**，说明更高 CE 倍率可能在“长跑尾段 top-10”上提供不同形状的收益。

12.3 NDCG@10




图 17: Instruments promising candidates: NDCG@10。

12.4 HR@10




图 18: Instruments promising candidates: HR@10。

12.5 NDCG@50




图 19: Instruments promising candidates: NDCG@50。

12.6 HR@50




图 20: Instruments promising candidates: HR@50。

12.7 怎么读这一组图

- 如果你只关心 headline top-10, **rule-only** 仍然是最靠上的线, 但它在 **HR@50** 图里会立刻暴露 coverage 损失。
- 如果你关心 clean fixed 主线, **fixed taskfix sid-only** 和 **fixed taskfix** 现在已经足

够稳定，而且一个更偏 top-10，一个更偏 coverage。

- 如果你关心新的最强候选，当前真正需要继续盯的不是单条 `fixed`，而是 `single-hint mixed`、`hintce-3` 和 `hintce-4`：前者更像完整长跑后的主候选，`hintce-3` 更像中段爆发出的高 coverage / 高 NDCG 候选，`hintce-4` 则更像把 top-10 延续到后段的高倍率版本。
- `old fixed mixed-single` 仍然有必要保留在图里，因为它提供了历史上界；但它只能当 historical reference，不能再当 clean 方法定义。

13 Hint-Token SFT: 去掉 RL 后的 Beam-Selected Hint Imitation

13.1 动机

前面的 CE family 都是在 GRPO / DAPO 主损失旁边加一个 prompt-side CE：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{RL}} + \lambda_{\text{CE}} \mathcal{L}_{\text{hint-CE}}.$$

这次新设定把问题拆得更干净：不再让 reward、advantage、KL/reference model 或 completion-token policy gradient 参与更新，而是只训练模型在应该暴露 oracle hint 的位置上模仿真实 SID prefix token。换句话说，beam search rollout 只负责决定“这个样本至少需要多少个 hint token 才能解出来”，最终梯度只来自这些被选中的 hint token。

13.2 代码入口

- Trainer: `hint_sft_trainer.py`
- fixed launcher: `hope/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec`
`sh`
- dynamic launcher: `hope/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-grec`
`sh`
- 合成单测: `tests/test_hint_sft_trainer.py`

这两个 launcher 默认都跑 Instruments mixed 三任务，不再启用 `sid-hint-only` 或 task filter。也就是说，训练分布仍然覆盖 `task1_sid_sft`、`task4_hisTitle2sid` 和 `task5_title_desc2sid`。

13.3 Fixed 版本

fixed 版本使用已有的 beam-hint 分析缓存作为 oracle depth 来源。启动脚本先调用 `analyze_rl_beam_hint.py`，从 `summary.json` / `details.json` 导出 fixed hint-depth map，然后把 map 注入训练集：

$$d_i = \text{fixed_hint_depth_map}(x_i).$$

对每个训练样本，prompt 后拼接由 ground truth SID 构造出来的前 d_i 个 oracle token。若 $d_i = 0$ ，该样本仍在 batch 中参与 padding 和 forward，但不会贡献 hint-token loss。若样本在离线 beam 分析里到最大深度仍未解出，默认使用 `fixed_hint_unsolved_depth=3`。

13.4 Dynamic 版本

dynamic 版本把“需要多少 hint token”的选择放到训练时在线完成。对一个 batch，trainer 从 depth 0 开始构造 hinted prompt，用当前模型做 constrained beam rollout；如果某个样本任意 beam completion 和 ground truth SID 精确匹配，就选中当前 depth。没有命中的样本进入下一层 depth，直到 `dynamic_hint_max_depth`。

需要强调的是：rollout completion 只是 selector，不进入监督标签。选中 depth 之后，真正反传的仍然只是 prompt 末尾的 oracle hint token CE。

13.5 Loss 细节

设拼好 hint 后的 token 序列为 $z_i = [x_i, h_i]$ ，其中 h_i 是 oracle hint prefix。代码构造 shift-label 位置上的 mask：

$$m_{i,t} = \begin{cases} 1, & z_{i,t+1} \in h_i, \\ 0, & \text{otherwise.} \end{cases}$$

训练 loss 是 masked token mean：

$$\mathcal{L}_{\text{hint-SFT}} = \lambda_{\text{SFT}} \frac{\sum_{i,t} m_{i,t} \text{CE}(p_{\theta}(\cdot | z_{i,\leq t}), z_{i,t+1})}{\sum_{i,t} m_{i,t}}.$$

实现上，DDP 下先 gather 全局 hint-token count，并把 denominator 按进程数缩放回每个 rank，这样各 rank 的梯度平均后等价于全局 token mean，而不是局部 token mean。若某个 batch 全局没有 hint token，则返回带梯度路径的 zero loss，避免反传时断图。

13.6 和之前 CE / RL 的区别

- 旧的 `fixed-hint-ce` 仍然先 rollout completion、算 reward、算 advantage，再用 RL loss 更新 completion policy；hint CE 只是旁路辅助项。
- 新的 hint-token SFT 完全去掉 reward 计算、advantage 标准化、old/ref log-prob、KL penalty 和 completion-token RL 更新。
- fixed 版本的 beam search 是离线 map 生成步骤；dynamic 版本的 beam search 是在线 depth selector。两者的共同点是 completion 本身都不作为 SFT 标签。
- 旧 CE 里 $\lambda_{\text{CE}} = 0.005$ 是加在 RL 主 loss 旁边的相对倍率；新 SFT 没有 RL 主 loss，所以不能直接继续用 `lr=1e-5`，`coef=0.005` 当作同一个优化设定。

13.7 学习率与 coef

这个 setting 已经不是 RL loss 旁边的辅助 CE，而是一个纯 masked SFT objective。因此默认学习率不再按 RL lr 和 hintce-3 系数相乘，而是对齐 Instruments full SFT 配置 `examples/train_full/Instruments/instruments_rec_full_sft_3b_dsz0_qwen4b_4_256_grec.yaml`：

$$\text{learning_rate} = 3.0 \times 10^{-4}, \quad \lambda_{\text{SFT}} = 1.0.$$

之前考虑过的 $10^{-5} \times 0.005 = 5 \times 10^{-8}$ 更适合解释“RL 主 loss 旁边的辅助 CE 有多重”，但放到纯 SFT 里会把 step size 压得过小。这里保留 $\lambda_{\text{SFT}} = 1.0$ ，让 loss 本身就是标准 masked token mean；后续如果发现训练不稳，更自然的消融是直接扫 `learning_rate`，例如 $1\text{e-}4$ 或 $3\text{e-}5$ ，而不是重新引入一个很小的 loss coef。

13.8 当前验证状态

本地已经覆盖三个轻量检查：

- masked batch builder 只在 prompt suffix 的 oracle hint token 上打 CE mask。
- fixed trainer 可以在合成数据上完整跑过一个 train step。
- dynamic selector 可以选中最小成功 depth，并记录 selected-depth metric。

此外两个启动脚本都跑过 `--dry-run`，确认默认 5 epoch、`lr=3.0e-4`、`hint_sft_loss_coef=1.0`，并且没有传入 task filter。真实结果跑完后，可以把 WandB / sidecar 指标接进现有 `docs/research/scripts/build` 画图流程。

14 结论与下一步

14.1 当前最稳的主故事

1. plain rule-only 仍然是当前 top-10 最强的无 hint baseline，但 coverage 损失很明确，因此不适合直接当 balanced 主线。
2. dynamic gather-fix 应被视为当前 canonical dynamic 实现；dynamic sid-only 和 ranking dynamic 都还没有超过它。
3. clean fixed family 仍然是当前最强的 balanced 主候选；其中 corrected fixed taskfix sid-only 是更干净的 fixed 参考，而 old fixed 只能当 historical reference。
4. 在后续探索里，max1 更像 early-stop dynamic candidate；hintce-3、hintce-4、fixed single-hint mixed 和 fixed dual-task 仍然是当前最成熟的新候选。相对地，新同步完整后的 dynamic hint + CE(0.005) 与 dynamic single-hint mixed 目前都没有改写 dynamic family 的排序。

5. 新增的 `fixed single-hint mixed + CE(0.005)` 现在已经补齐完整轨迹；按当前 `full-trace` 对照看，它仍然没有把 `single-hint mixed` 和 `hintce-3` 的优势自然合并起来，因此暂时不应被当作新的主候选。

14.2 下一步最值得继续补的证据

- 解释 `hintce-3` 为什么在完整尾段已经补齐后，`best` 点仍停在中段而不是最终点，并确认它该被当作峰值候选还是稳态候选。
- 继续跟 `single-hint mixed` 的尾段平台，并解释为什么它能在完整 2 epoch 维持住 `fixed family` 前沿。
- 对 `single-hint mixed + CE(0.005)`，当前更值得做的是解释为什么它没有继承 `plain single-hint mixed` 和 `hintce-3` 的优势，而不是继续把它默认当成等待后段翻盘的候选。
- 继续跟 `dynamic dual-task` 与 `fixed dual-task` 的终段 readout，确认 `dual-task family` 的稳定排序。
- 对 `dynamic hint + CE(0.005)` 和 `dynamic single-hint mixed` 这两条线，当前更值得做的是解释它们为什么在 `early-window` 看起来有信号，但长跑后没有转化成真正的主候选，而不是再把它们默认当成最优先的加算力对象。
- 如果后面要把这份稿件扩成更正式的研究报告，建议继续沿用“一个实验主题一个子文件”的结构，而不是回到按日期拼接的 `note` 模式。

14.3 Games 当前定位

- Games 现在已经足够作为正式附录收录，因为它不再只是一套脚本和早期 readout，而是完整覆盖了 `index -> preprocess -> SFT -> RL`。
- 在第二个数据集上，`fixed-hint` 继续是当前最强、最平衡的主候选，而 `rule-only` 继续体现 `top-10` 与 `coverage` 的交换。
- 这意味着 Instruments 上的主结论目前并不是单数据集偶然，但 Games 还需要 `task-level readout` 才能继续往机制解释推进。

A Games-grec 全流程摘要

A.1 为什么把 Games 放进附录

当前这份研究稿主体仍然围绕 `Instruments-grec` 展开，因为那条线的变体更完整、家族内部对照也更多。相比之下，`Games-grec` 已经足够形成一条可复用的“单数据集 `index -> preprocess -> SFT -> RL`”流水线，但更适合作为附录收录：

- 它已经能独立支撑一条完整的结果线，而不再只是实验脚手架。

- 它当前最重要的价值，是验证 `fixed-hint > dynamic-hint > SFT` 这条大故事在另一个数据集上是否继续成立。
- 它还没有像 Instruments 那样展开大量 family-internal ablation，因此不适合和正文混在同一层级叙述。

A.2 Index 与下游数据

项目	当前记录
Dataset	Games
Embedding model	qwen3-embedding-4B
Index config	rq4(cb256-256-256-256)
Final collision rate	0.0075873
Max conflict count	5
Layer utilization	第 0 层 47/256; 第 1/2/3 层 256/256
稳定 alias	Games.index_emb-qwen3-embedding-4B_... _dsGames.json

表 15: Games semantic index 的当前关键配置与结果。

导出集合	规模	备注
SFT train	520761	含 Task1/2/3 组合后的最终导出
SFT valid	42259	与 test 同量级
SFT test	42259	当前统一评测入口使用
RL train	280110	含 Task1/4/5
RL valid	42259	当前主要用于统一评测
RL test	42259	与 SFT test 对齐

表 16: Games-grec 下游数据导出规模。

这里最重要的读法只有两点：

- 这个 Games index 的碰撞率已经低到足以进入下游 SFT/RL；后续重点不再是“能不能用”，而是“第 0 层 codebook 为什么利用率这么低”。
- Games_grec 已经不是只做了基础 preprocess 的半成品，而是完整支持统一 SFT / RL / evaluate 的正式变体。

A.3 SFT checkpoint 选择

对应入口

- SFT YAML: `examples/train_full/Games/games_rec_full_sft_3b_dsz0_qwen4b_4_256_grec.yaml`
- RL 默认初始点: `Games-grec-sft-qwen4B-4-256-dsz0/checkpoint-896`
- 本地出图脚本: `docs/research/scripts/build_games_report_figures.py`

Checkpoint	NDCG@10	HR@10	NDCG@50	HR@50
checkpoint-640	0.0426	0.0788	0.0680	0.1958
checkpoint-768	0.0433	0.0804	0.0691	0.1998
checkpoint-896	0.0430	0.0790	0.0687	0.1970
checkpoint-1024	0.0374	0.0692	0.0597	0.1729

表 17: Games SFT 后段 checkpoint 选择。




图 21: Games SFT checkpoint selection; 虚线标出 best NDCG@10 的 checkpoint-768, 点线标出 RL 默认初始化点 checkpoint-896。

这一段 SFT 的结论很清楚：

- 如果只按 best NDCG@10 选点，当前最强 SFT checkpoint 是 768。
- 如果目的是继续接 RL，896 仍然是更稳妥的初始化点，因为它仍处在后段高性能平台里，但还没掉到 1024 那种明显回落区间。
- 因此后文里的 Games RL，默认都把 checkpoint-896 当作统一起点。

B Games-grec RL 结果

B.1 对应 launcher

- launcher 目录：hope/Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-Games-grec/

- rule-only: `Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-Games-grec-rl-rule-only.sh`
- dynamic-hint: `Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-Games-grec-rl-rule-only-dynamic-hint.sh`
- fixed-hint: `Qwen2_5-3B-Isntruct-qwen4B-4-256-MIMIGenRec-Games-grec-rl-rule-only-fixed-hint.sh`
- 本地出图脚本: `docs/research/scripts/build_games_report_figures.py`

B.2 最好点与 coverage 峰值

Variant	Best ckpt	NDCG@10	HR@10	NDCG@50	HR@50
SFT best	<code>checkpoint-768</code>	0.0433	0.0804	0.0691	0.1998
RL rule-only	<code>checkpoint-8752</code>	0.0467	0.0825	0.0683	0.1815
RL dynamic-hint	<code>checkpoint-4380</code>	0.0464	0.0823	0.0716	0.1980
RL fixed-hint	<code>checkpoint-8752</code>	0.0480	0.0857	0.0723	0.1972

表 18: Games-grec 上 SFT 与三条 RL 主线的最好点。

Variant	Peak ckpt	HR@50	Peak HR@50	同点 NDCG@10
RL rule-only	<code>checkpoint-4380</code>	0.1851		0.0463
RL dynamic-hint	<code>checkpoint-3504</code>	0.1981		0.0461
RL fixed-hint	<code>checkpoint-3504</code>	0.2024		0.0478

表 19: Games RL 三条线的 coverage 峰值。

从这两张表可以直接读出当前阶段性排序：

- 按 best NDCG@10 看，Games 当前已经形成 `fixed-hint` > `rule-only` $\gtrsim$ `dynamic-hint` > SFT。
- plain rule-only 继续体现出和 Instruments 相同的模式：top-10 变强，但 HR@50 掉得最明显。
- dynamic-hint 仍然是很有竞争力的第二梯队；它在自己 best top-10 点上的 HR@50 仍略高于 late-stage fixed-hint。
- 如果改按 coverage 峰值而不是 best NDCG@10 checkpoint 读，fixed-hint 的 `checkpoint-3504` / HR@50=0.2024 仍然是全场最强点。

B.3 RL 曲线图




图 22: Games RL metric curves; 灰虚线是 SFT best checkpoint-768 的水平参考线。

这张图更适合用来解释“最佳点为什么不在同一时刻”：

- **rule-only** 在 NDCG@10 上还能慢慢涨到尾点，但 HR@50 很早就进入平台区，后面也没有明显恢复。
- **dynamic-hint** 的最佳窗口集中在 epoch≈1.0 左右；同步到完整 2 epoch 之后，它并没有继续把 top-10 往上抬。
- **fixed-hint** 呈现很典型的“两段式最优”：中前段先拿到全场最强 coverage，训练末端再把 NDCG@10 / HR@10 推到新的最高点。

B.4 最好点 trade-off




图 23: Games best NDCG@10 vs HR@50 scatter。

如果把每条线都压成一个 best 点，这张散点图最值得记住三件事：

- 最靠右的是 **fixed-hint**，说明它当前已经拿到了 Games 上最强的 top-10 点。
- **dynamic-hint** 虽然右移不如 **fixed-hint**，但它在自己 best 点上的 HR@50 仍然处在高位，因此它不是失败 run，而是“coverage 更稳、top-10 略弱”的第二梯队。
- **rule-only** 则明显更靠下，说明它在 Games 上也复现了“top-10 强、coverage 弱”的交换。

B.5 当前读法

把 Games 这条线纳入附录之后，当前最稳妥的总结是：

1. **Games-grec** 已经不再只是辅助数据集，而是完成了一条可复用的单数据集全流程。
2. 在第二个数据集上，**fixed-hint** 仍然是当前最平衡的主线，说明 Instruments 上的主故事并不是单点偶然。
3. **dynamic-hint** 仍然有明确价值，但它现在更像“覆盖率更稳的次优 family”，而不是已经改写主线排序的方案。
4. 如果后面继续扩 Games，最值得补的是 task-level readout，以及 **fixed-hint** 的 best-top10 点和 best-coverage 点之间到底该如何汇报。