GenRec Instruments-grec RL 研究合并稿

基于 2026-04-11 / 2026-04-16 / 2026-04-19 三篇实验 note 整理

2026-04-21

摘要

这是一份面向持续迭代的 LaTeX 研究稿初版，先把 `Instruments-grec` 上三篇核心实验 note 合并到同一份文档里。当前重点不是一次性写成终稿，而是先建立一个可长期续写的结构：总览、七线主比较、dynamic max1 消融、dual-task 与 single-hint tracking，以及统一的结论与后续动作。

目录

1 文档总览 **2**
- 1.1 合并范围 . . . 2
- 1.2 共享背景 . . . 2
- 1.3 为什么现在先转成 LaTeX . . . 2
- 1.4 本稿当前结构 . . . 3

2 七线主比较与 Fixed-Hint CE 补充 **3**
- 2.1 本章目的 . . . 3
- 2.2 统一比较口径 . . . 3
- 2.3 主表：按 best NDCG@10 选点 . . . 5
- 2.4 主图与主判断 . . . 6
- 2.5 Fixed-Hint CE 变体 . . . 7
- 2.6 本章小结 . . . 8

3 Dynamic-Hint Max1 消融 **9**
- 3.1 实验问题 . . . 9
- 3.2 改动范围 . . . 9
- 3.3 关键指标 . . . 11
- 3.4 图表阅读 . . . 13
- 3.5 本章小结 . . . 14

4 Dual-Task 过滤与 Single-Hint Mixed 跟踪 **15**
- 4.1 本章研究问题 . . . 15
- 4.2 新 setting 一览 . . . 15

4.3 single-hint mixed：已经进入 fixed family 前沿 15
4.4 dual-task family：fixed 已经整体强于 dynamic 17
4.5 新增同步：hintce-3 18
4.6 本章小结 19

5 统一结论与后续整理建议 19
5.1 目前最稳的主故事 19
5.2 这份 LaTeX 稿下一步可以怎么扩 20

1 文档总览

1.1 合并范围

本稿当前先合并三篇和 `Instruments-grec` RL 主线最相关的实验 note：

- 2026-04-11：七线主比较 + fixed-hint CE 补充
- 2026-04-16：dynamic-hint max1 消融
- 2026-04-19：dual-task 过滤 / single-hint mixed tracking

这三篇的关系并不是平行重复，而是三层递进：

1. 2026-04-11 给出当前最常用的主 baseline 版图，是总览层。
2. 2026-04-16 专门回答 dynamic family 里的一个 focused ablation：把 online hint budget 从“最大深度为 3”收紧到“最大深度为 1”之后会发生什么。
3. 2026-04-19 继续沿着“任务过滤 / hint 只施加到部分任务”这条线，记录 single-hint mixed、dynamic dual-task、fixed dual-task 和 hintce-3 的新进展。

1.2 共享背景

三篇 note 共享的研究背景基本一致：

- 数据集与任务：`Instruments-grec`
- RL 起点：`Instruments-grec-sft-qwen4B-4-256-dsz0/checkpoint-495`
- 常用对比维度：top-10 质量、top-50 coverage、是否依赖 hint scaffold、是否会出现 early coverage spike、是否能在完整 2 epoch 尾段维持优势

其中最重要的阅读原则有两个：

1. 主表默认按 best `NDCG@10` 选点，但不能只看一个 best 点，还要同时记录 peak `HR@50` 和 final/latest readout。
2. 不同 run 的完整训练 step horizon 不总是一样，因此横轴统一成 epoch 时，必须写清楚归一化口径。

1.3 为什么现在先转成 LaTeX

把三篇 note 合并成 LaTeX，当前主要是为了解决两个问题：

- 给后续持续更新留一个更稳定的结构，而不是每次新结果出来都重新发明一篇 Markdown。
- 让图表、表格、结论和后续动作开始形成可组合的“章”级结构，后面无论是继续扩写为长报告，还是拆成更细的实验小稿，都更容易维护。

1.4 本稿当前结构

章节	作用	当前内容
七线主比较	建立 baseline 地图	rule-only、dynamic、fixed、CE 变体的统一总览
dynamic max1 消融	focused ablation	回答浅 hint budget 是否能把 dynamic family 推向更好的 trade-off
dual-task / single-hint tracking	持续跟踪新探索	记录 dual-task filtered 与 single-hint mixed 两类新设定的完整轨迹

2 七线主比较与 Fixed-Hint CE 补充

2.1 本章目的

这一章对应 2026-04-11 的主比较 note,作用是把当前最常被一起讨论的几条 `Instruments-grec` RL 线放到同一个框架里，优先回答两个问题:

1. 如果只按 top-10 排，谁最强。
2. 如果同时看 top-10 和 coverage，哪条线最平衡。

2.2 统一比较口径

- SFT 参考点：`checkpoint-495`
- 主表选点：按 best `NDCG@10` 选 checkpoint
- 覆盖峰值：另外记录 peak `HR@50`，用于识别 early spike
- 横轴：统一成 epoch；其中 `sid-only` family 按各自完整训练长度 `2652 step = 2 epoch` 归一化，其余主线按 `3326 step = 2 epoch` 归一化

2.3 主表：按 best NDCG@10 选点

Variant	Best ckpt	Epoch	NDCG@10	HR@10	NDCG@50	HR@50	读法
SFT495 reference	checkpoint-495	–	0.0823	0.1094	0.0985	0.1844	RL 对照基线
rule-only rerun	checkpoint-2997	1.802	0.0960	0.1179	0.1070	0.1681	top-10 全场最好，但 coverage 最弱
dynamic hint sid-only	checkpoint-2394	1.805	0.0921	0.1155	0.1065	0.1830	比 plain rule-only 更平衡，但还不够强
dynamic hint gather-fix	checkpoint-2997	1.802	0.0936	0.1169	0.1083	0.1855	当前 dynamic family 默认基线
ranking dynamic cascade	checkpoint-1665	1.001	0.0911	0.1138	0.1058	0.1822	中期见顶，后期

2.4 主图与主判断

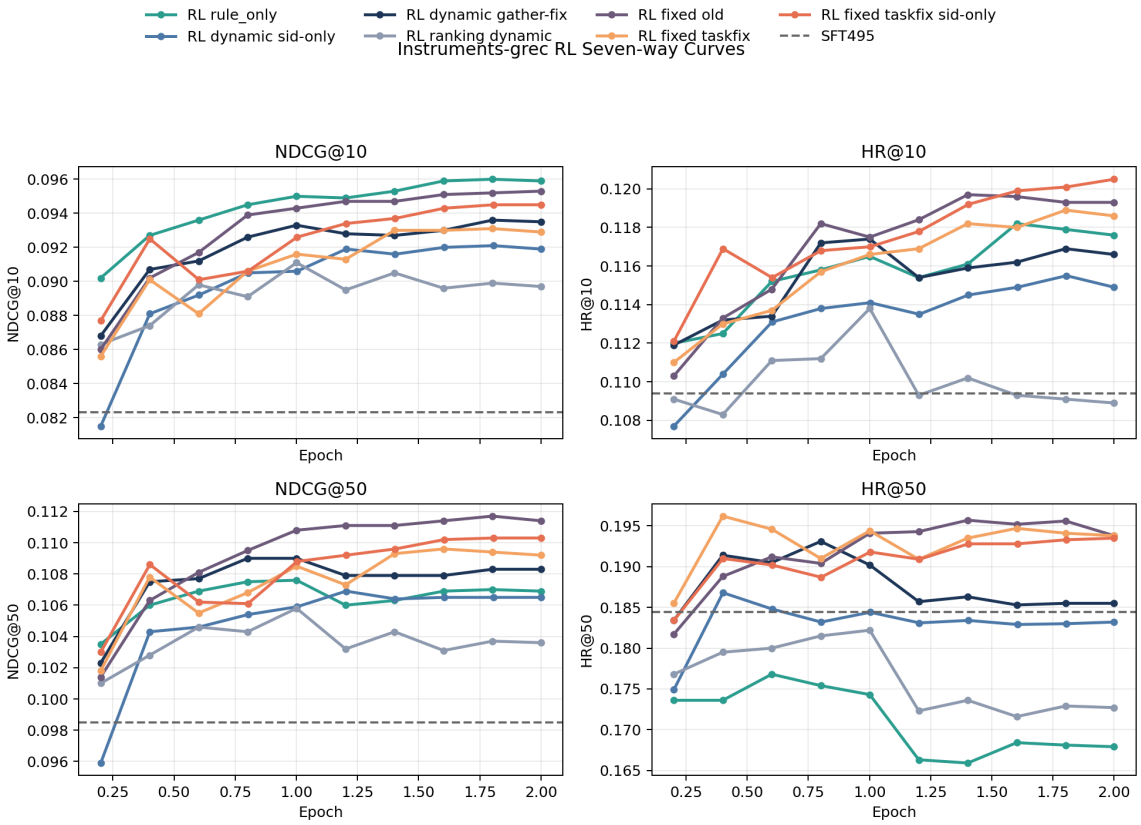

图 1: 七线主比较曲线。

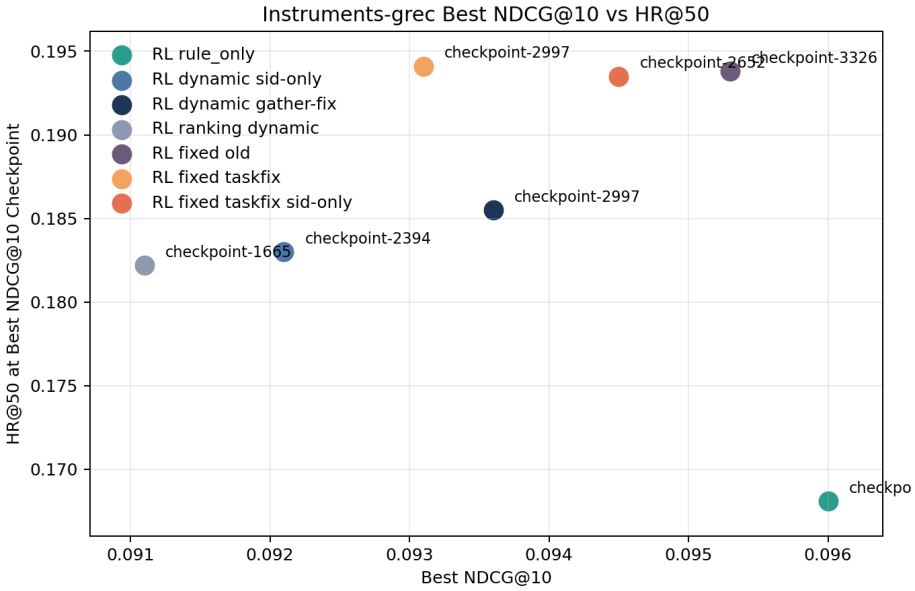

图 2: best NDCG@10 对应的 top-10 / coverage trade-off。

这一组图压缩出来的结论很清楚：

1. `rule-only rerun` 仍然是当前最强的 top-10 极值线，但 coverage 明显差，不能直接当 balanced 主线。
2. dynamic family 里，`gather-fix` 仍然是唯一长期表现稳定、并且 best 点还能把 `HR@50` 拉到 SFT 水平之上的 run。
3. fixed family 整体仍然占据图里的右上区域。即使把 old fixed 当作带 caveat 的历史参考，clean fixed 线仍然明显强于 dynamic family。

2.5 Fixed-Hint CE 变体

Variant	Best ckpt	Epoch	NDCG@10	HR@10	NDCG@50	HR@50	Peak HR@5
fixed taskfix	checkpoint-2997	1.802	0.0931	0.1189	0.1094	0.1941	0.1962
fixed taskfix + CE	checkpoint-2664	1.602	0.0915	0.1180	0.1081	0.1944	0.1947
fixed taskfix + CE (hintce-2)	checkpoint-2664	1.602	0.0931	0.1168	0.1102	0.1951	0.1954

表 3: fixed taskfix 的 CE variants vs non-CE。

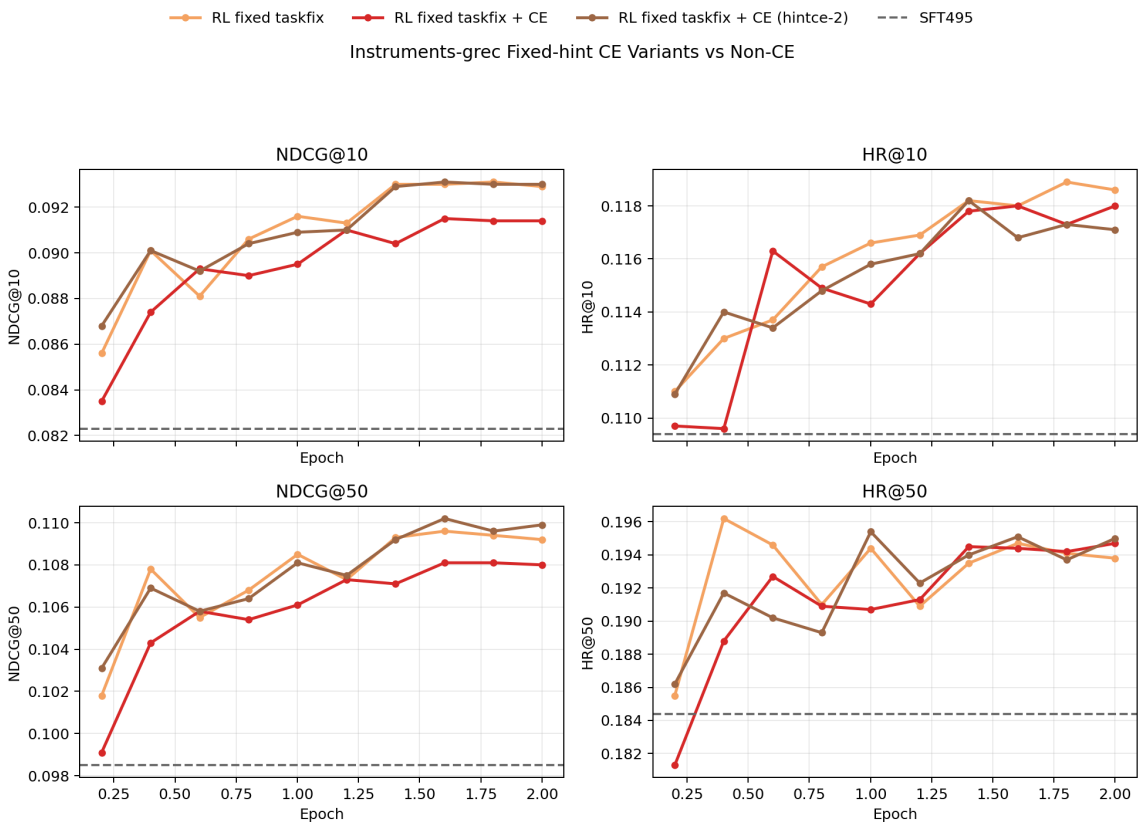

图 3: fixed taskfix 的 CE variants vs non-CE 曲线。

这一块最重要的不是“CE 一定更好”，而是：

- full `+CE` 更像正则项，能把轨迹变平，但 headline top-10 仍然不够强。
- `hintce-2` 已经不再只是 early-window readout，而是一个完整轨迹上更有前景的 CE 候选。
- 即便如此，fixed family 的主问题仍然没有变成“再堆 CE 系数”，而是如何在不损失平衡性的前提下把 clean fixed 主线继续抬高。

2.6 本章小结

1. 当前主比较应该继续保留四类 reference：plain rule-only、dynamic gather-fix、clean fixed sid-only、historical old fixed。
2. 如果目标是 coverage，不应该只看最终 checkpoint；fixed taskfix 的 early coverage spike 仍然值得单独跟。
3. 如果继续追 CE，最值得追的是 `hintce-2` 一类“中后段 balanced 优势更强”的变体，而不是简单继续堆更多命名。

3 Dynamic-Hint Max1 消融

3.1 实验问题

这一章对应 2026-04-16 的 focused ablation。它只回答一个具体问题：

> 如果把 dynamic hint 的 online budget 从 `dynamic_hint_max_depth=3` 收紧到 `1`，而不改 trainer 逻辑、不丢 no-hit 样本，最后的 eval trade-off 会落在什么位置。

3.2 改动范围

维度	baseline	max1 实验	备注
reward mode	rule-only	rule-only	不变
num beams	16	16	不变
dataset variant	Instruments-grec 主线数据	相同	不变
trainer 收口逻辑	当前 dynamic trainer	相同	不变
样本筛除	不丢 no-hit 样本	不丢	不变
hint budget	max depth 3	max depth 1	唯一改动

表 4: max1 消融的唯一改动是 online hint budget。

3.3 关键指标

Variant	Best ckpt	Epoch	NDCG@10	HR@10	NDCG@50	HR@50	读法
rule-only rerun	checkpoint-2997	1.802	0.0960	0.1179	0.1070	0.1681	top-10 最强，但 coverage 最低
dynamic hint sid-only	checkpoint-2394	1.805	0.0921	0.1155	0.1065	0.1830	早期有 gain，后面偏平
dynamic hint gather-fix	checkpoint-2997	1.802	0.0936	0.1169	0.1083	0.1855	当前长跑 dynamic baseline
dynamic hint max1	checkpoint-1332	0.801	0.0934	0.1158	0.1095	0.1905	best 点停在中前段
corrected fixed taskfix sid-only	checkpoint-2652	2.000	0.0945	0.1205	0.1103	0.1935	clean fixed 上界参考

表 5: max1 与主要 baseline 的 best-point 对照。

Variant	Peak ckpt	Epoch	Peak HR@50	NDCG@10 at peak	读法
rule-only rerun	checkpoint-999	0.601	0.1768	0.0936	coverage 峰值低，而且很早就掉下去
dynamic hint sid-only	checkpoint-532	0.401	0.1868	0.0881	典型 early spike
dynamic hint gather-fix	checkpoint-1332	0.801	0.1931	0.0926	当前长跑 dynamic 的 coverage 峰值
dynamic hint max1	checkpoint-999	0.601	0.1907	0.0925	比 sid-only 和 rule-only 都高
corrected fixed taskfix sid-only	checkpoint-2652	2.000	0.1935	0.0945	仍然更稳

表 6: max1 的 coverage 峰值仍低于 gather-fix 与 clean fixed。

3.4 图表阅读

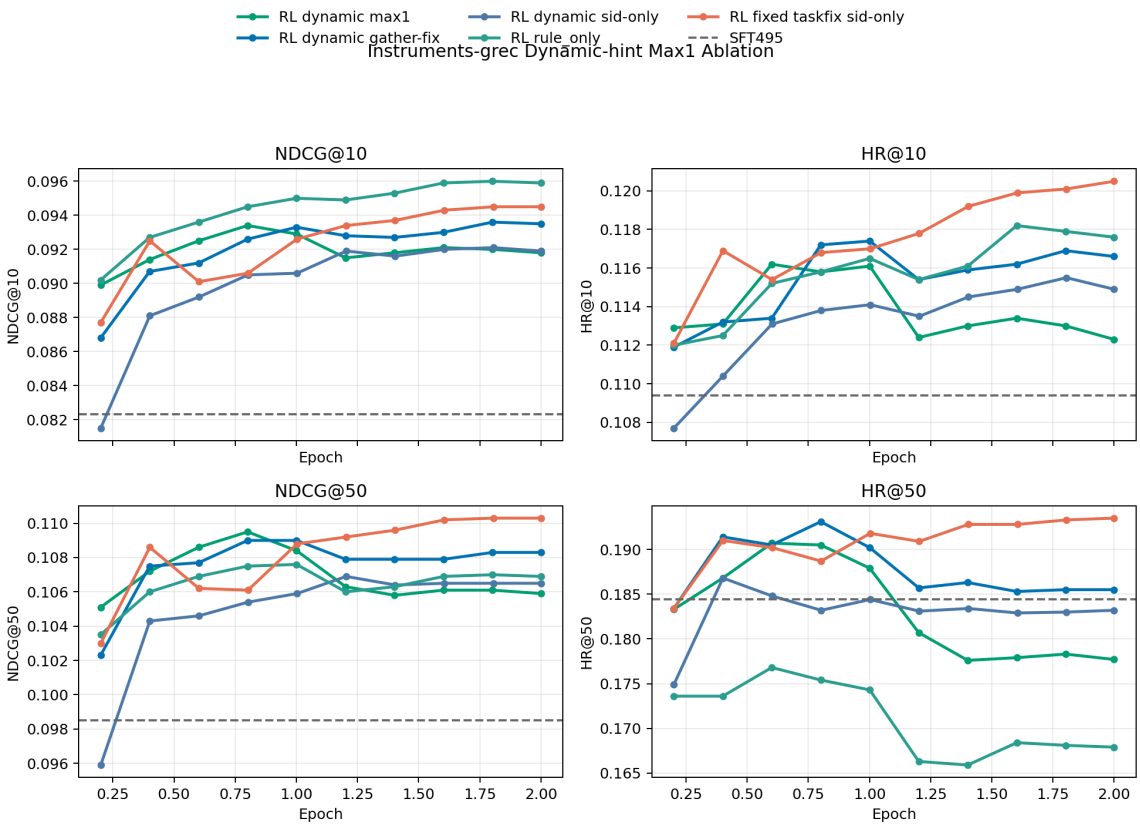

图 4: max1 ablation epoch curves。

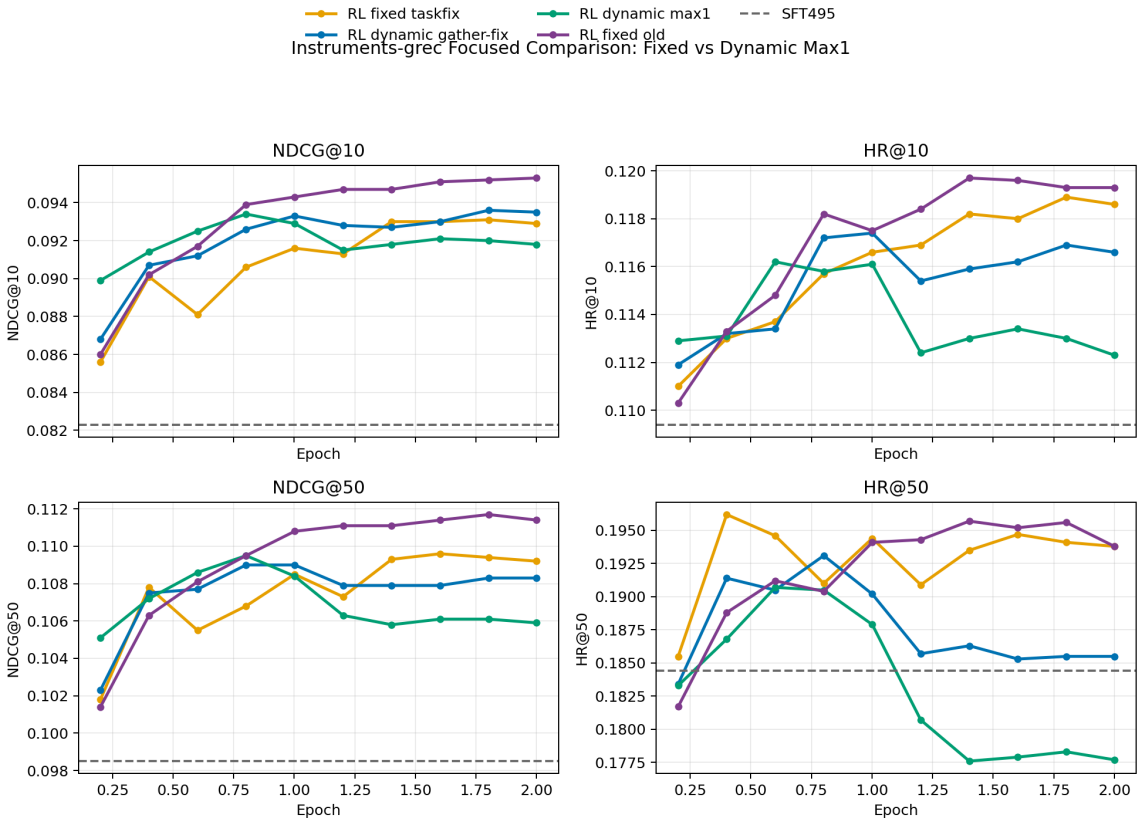

图 5: max1 与 dynamic/fixed 参考线的 focused four-way comparison。

把图和表放在一起看，现象其实很一致：

1. `max1` 不是简单退化成 `rule-only`。它在很多 checkpoint 上保住了更高的 coverage，说明浅 budget 不是直接把 hint 机制废掉。
2. `max1` 也不是被 `gather-fix` 完全支配。它在早中段几个关键点上能给出更高的 `NDCG@10`，而且 coverage 并没有同步塌掉。
3. 但完整轨迹现在已经表明，`max1` 的优势主要停在前中段。跑到 `checkpoint-3326` 以后，它没有把优势延续到尾段，反而逐步回落。
4. 因此它更像一个值得 early-stop 的 dynamic candidate，而不是新的 long-run default。

3.5 本章小结

- 如果后续 dynamic family 只保留一个长期默认线，当前仍然应优先保留 `gather-fix`。
- 如果后续研究 early-stop 或 shallow-budget trade-off，`max1` 仍然非常值得继续跟。
- 真正缺的不是更多 eval 点，而是 train-time diagnostics。没有日志，当前对机制的解释仍然只能停留在假说层。

4 Dual-Task 过滤与 Single-Hint Mixed 跟踪

4.1 本章研究问题

这一章对应 2026-04-19 的 tracking note。它实际上覆盖两类新问题：

1. 只训练两个任务：从 mixed RL 三任务里移除 `task4`，只保留 `task1 + task5`。
2. 只 hint 一个任务：训练仍保留 mixed task，但 fixed hint 只注入 `task1`。

这轮虽然有三个 launcher，但研究问题只有两类，因此这一章按研究问题分组，而不按 launcher 分组。

4.2 新 setting 一览

Setting	训练任务	hint 机制	说明
dynamic dual-task	`task1 + task5`	dynamic hint	只训练两个任务，eval 仍看 task1
fixed dual-task	`task1 + task5`	fixed hint	beam hint export 也只针对 dual-task 子集
single-hint mixed	mixed 三任务	fixed hint 仅给 task1	task4/task5 继续训练，但按 zero-hint 路径走

表 7: 2026-04-19 tracking note 中最重要的三个新 setting。

4.3 single-hint mixed：已经进入 fixed family 前沿

Variant	Best ckpt	Epoch	NDCG@10	HR@10	NDCG@50	HR@50
dynamic gather-fix	checkpoint-2997	1.802	0.0936	0.1169	0.1083	0.1855
dynamic dual-task	checkpoint-1510	1.003	0.0930	–	–	0.1885
fixed old	checkpoint-3326	2.000	0.0953	–	–	0.1938
fixed taskfix	checkpoint-2997	1.802	0.0931	–	–	0.1941
fixed taskfix sid-only	checkpoint-2652	2.000	0.0945	–	–	0.1935
single-hint mixed	checkpoint-2664	1.602	0.0948	0.1180	0.1116	0.1958

表 8: single-hint mixed 已经可以放进主 baseline 族里一起比较。

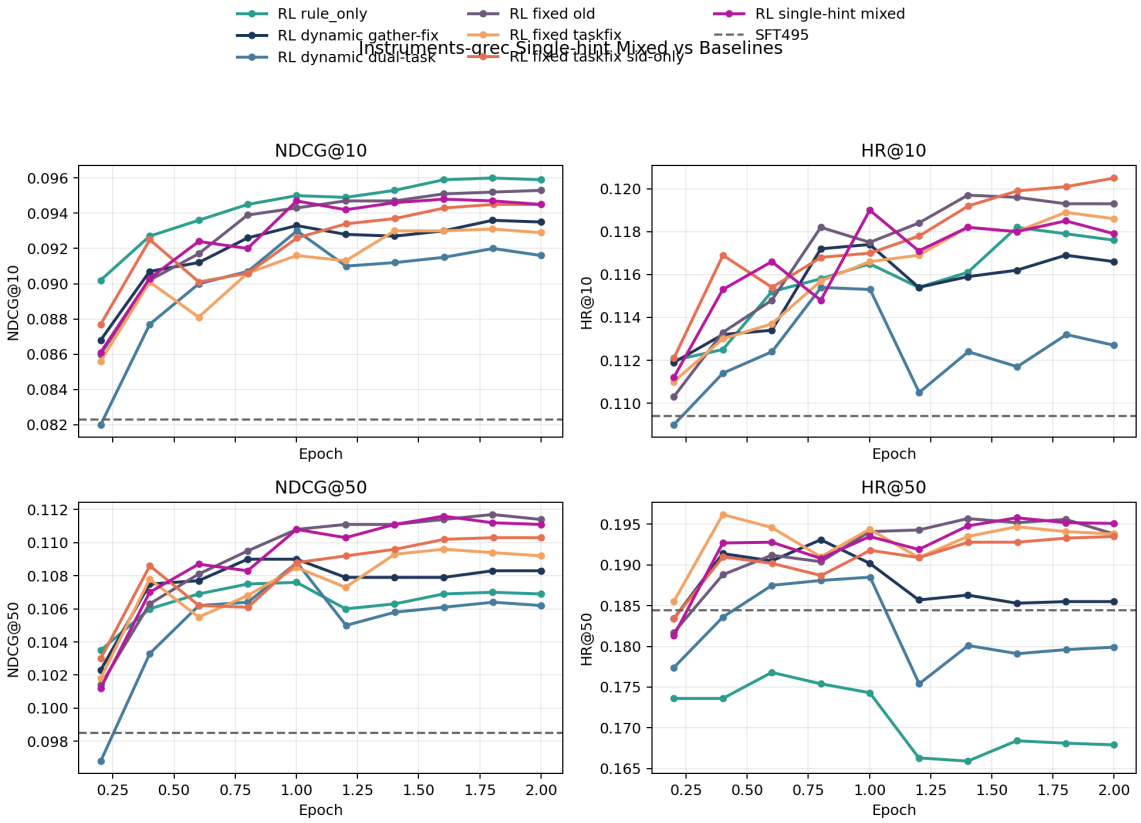

图 6: single-hint mixed vs baselines。

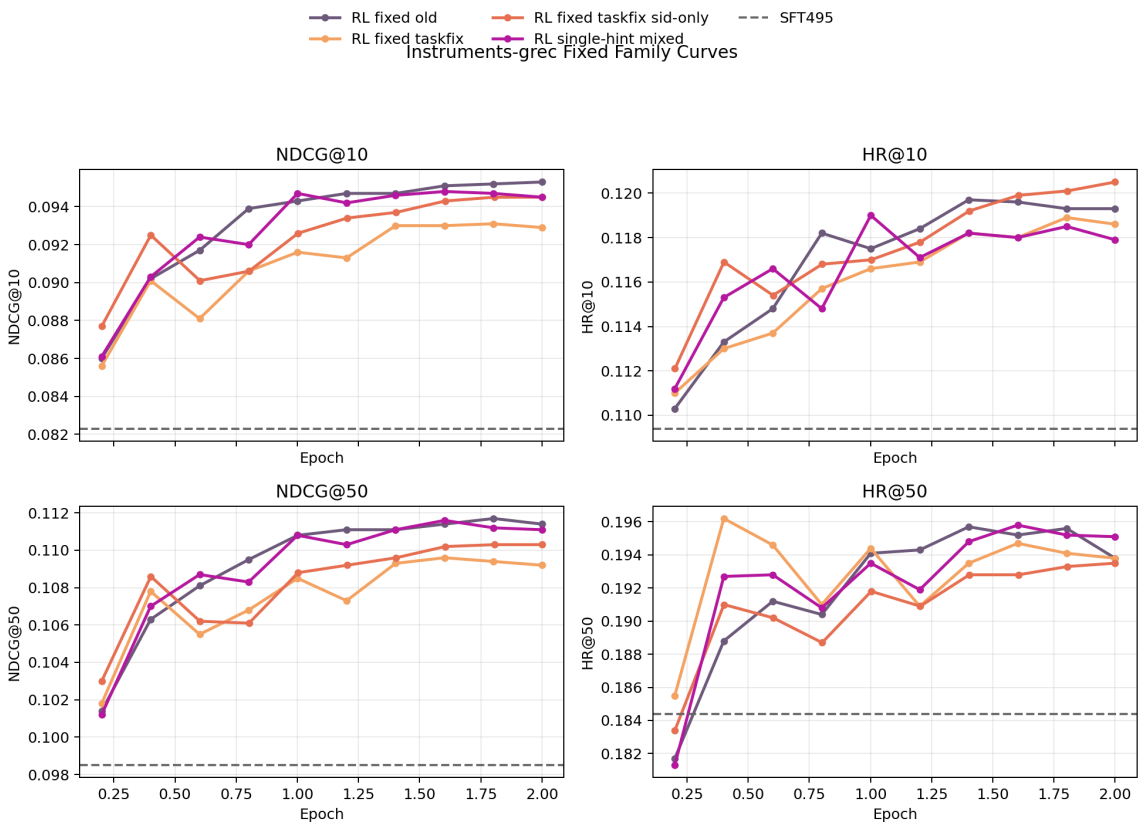

图 7: single-hint mixed vs fixed family。

这部分当前最重要的判断是：

1. `single-hint mixed` 已经不只是一个有信号的新 launcher，而是开始站到 fixed family 的前沿区域。
2. 它当前 full-trace best 点 `0.0948 / 0.1958` 已经同时超过 corrected `fixed taskfix sid-only` 的 `0.0945 / 0.1935`。
3. 它对 old fixed 仍然略差一点 top-10，但 coverage 已经更高，因此后续真正值得解释的是：为什么它能在完整尾段维持住这个高位平台。

4.4 dual-task family：fixed 已经整体强于 dynamic

Variant	Best ckpt	Aligned epoch	NDCG@10	HR@50	读法
dynamic dual-task	checkpoint-1510	1.861	0.0930	0.1885	完整轨迹已可比，但 best 仍停在中段
fixed dual-task	checkpoint-2718	1.972	0.0939	0.1897	后半段持续抬升，整体略强于 dynamic dual-task

表 9: dual-task family 的 aligned comparison。

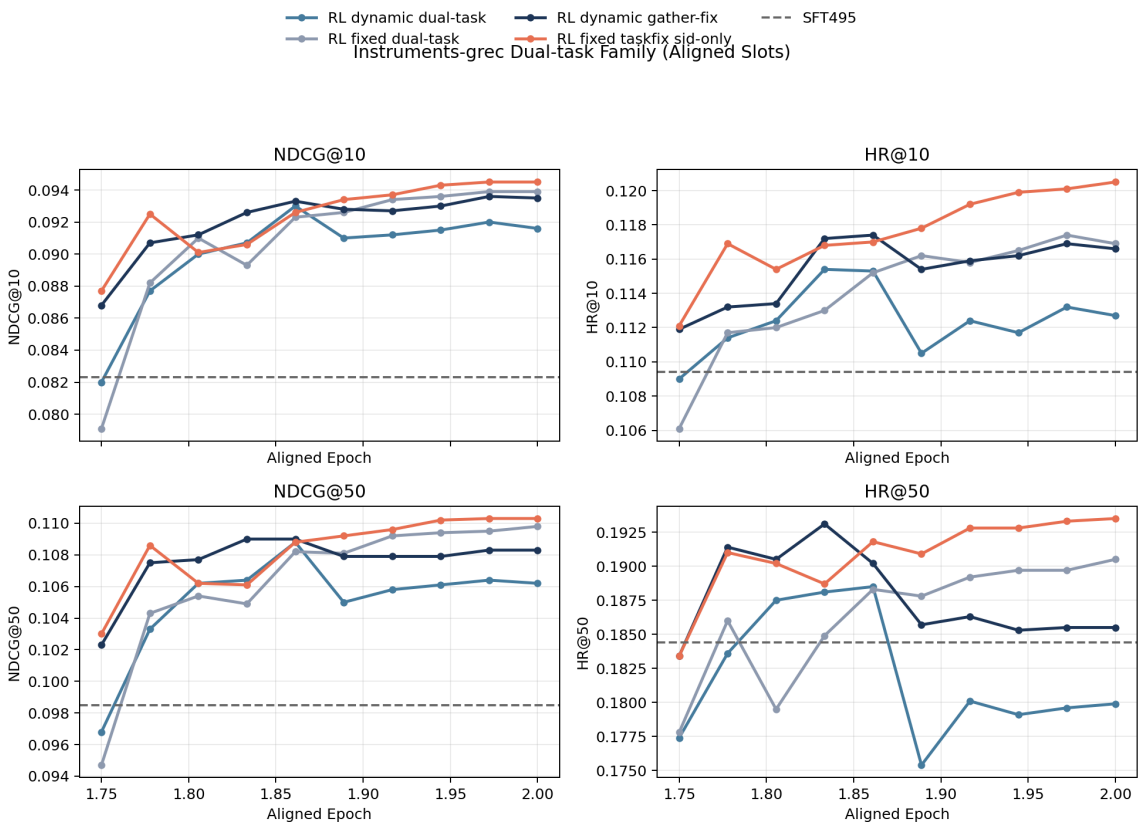

图 8: dual-task family aligned curves。

现在这条线已经可以明确写成：

- fixed dual-task 不再只是 early look，而是一条完整可比轨迹。
- 相比 dynamic dual-task，它不再只是交换 top-10 与 coverage，而是整体略占优。
- 但它离 clean fixed 主线仍然有明显差距，所以更准确的定位是“dual-task 版本里 fixed 比 dynamic 更强”，而不是“dual-task 已经进入 fixed 主线最前排”。

4.5 新增同步：hintce-3

Variant	Synced ckpts	Best ckpt	Epoch	NDCG@10	HR@50
fixed taskfix	333..3326	checkpoint-2997	1.802	0.0931	0.1941
hintce-2	333..3326	checkpoint-2664	1.602	0.0931	0.1951
hintce-3	333..2997	checkpoint-1665	1.001	0.0945	0.1985

表 10: hintce-3 已从 early readout 变成中后段强候选。

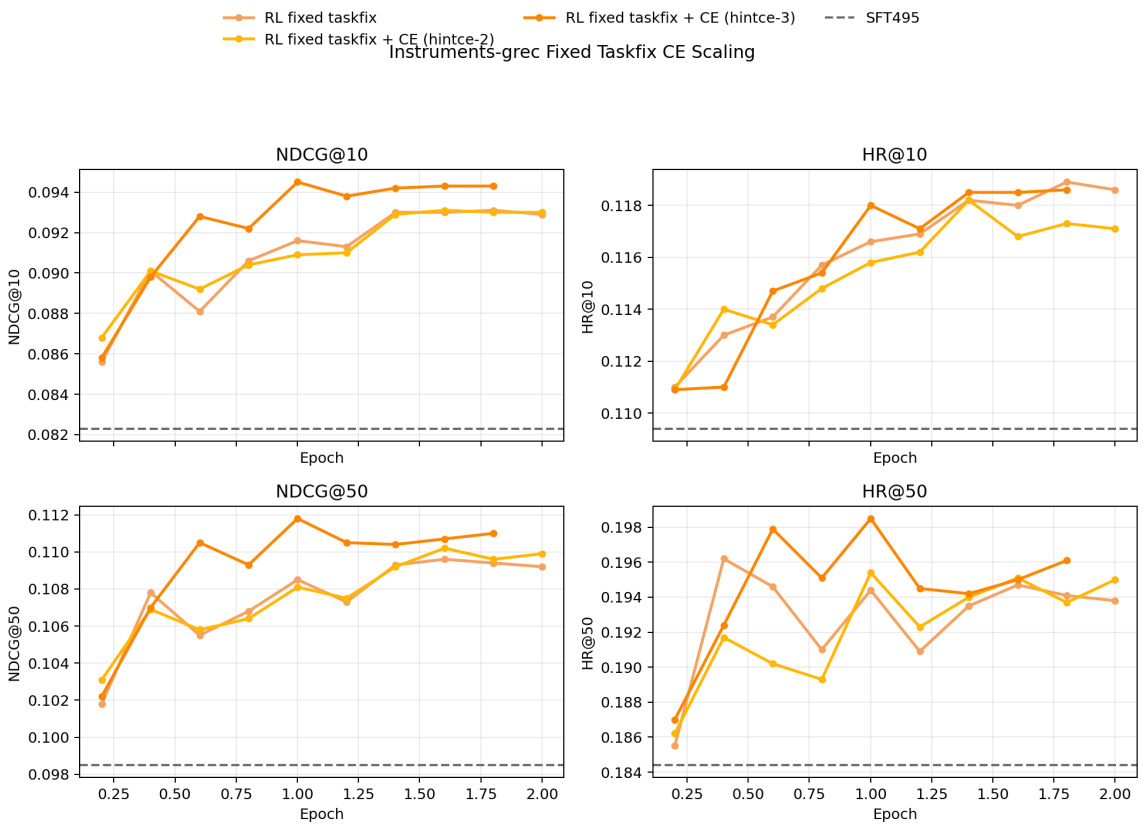

图 9: hintce scaling curves。

截至当前同步状态，`hintce-3` 的含义已经变了：它不再只是一个“只有两个 early 点”的暂存结果，而是一条已经足够进入主候选讨论范围的轨迹。只是它是否能成为稳态新上界，仍然要看最后一段 checkpoint。

4.6 本章小结

1. `single-hint mixed` 是这一轮最值得继续追的主候选之一，因为它已经在完整尾段维持住了 fixed family 前沿水平。
2. fixed dual-task 已经可以当作“比 dynamic dual-task 更强”的 clean 结论，但它还没有打入当前 fixed 主线最前排。
3. `hintce-3` 已经从 early readout 升级成中段强峰值候选，后续只差最后一段 terminal readout 来判断它是不是稳态新上界。

5 统一结论与后续整理建议

5.1 目前最稳的主故事

1. plain `rule-only` 仍然是当前 top-10 最强的无 hint baseline，但 coverage 损失很明确，因此不适合直接当 balanced 主线。

2. clean fixed-hint family 仍然是当前最稳定的主候选。即使不再把带 legacy caveat 的 old fixed 当作方法定义，它也没有改变这一点。

3. dynamic family 不是没有价值，但目前更像是提供局部 trade-off 改善，而不是整体打穿 fixed family。`gather-fix` 仍是长跑默认 dynamic baseline，`max1` 更像 early-stop candidate。

4. 2026-04-19 之后，single-hint mixed 已经从“旁支尝试”进入 fixed family 前沿区域；dual-task fixed 也已经从 very-early look 进入完整可比轨迹。

5.2 这份 LaTeX 稿下一步可以怎么扩

- 继续沿用“一个实验组一个子文件”的方式扩写，而不是回到单篇超长 Markdown。
- 把公共元信息继续上收，例如统一的 baseline 表、结果同步状态、图表风格、W&B 链接和脚本路径。
- 后续如果要写成更正式的研究报告，可以把本稿继续拆成：
  - 主比较正文
  - dynamic family 专章
  - fixed family 与 CE 专章
  - 双任务/单任务 hint 新探索专章
- 图表层后续最好再统一成一套可复用脚本和样式文件，这样 LaTeX 侧就只负责排版，不再手工对每篇实验单独适配。