GenRec Instruments 数据集 RL 实验整理

按实验主题重构的 LaTeX 研究稿

2026-04-21

摘要

本文把 `Instruments-grec` 上已经跑出来的主要 RL 实验按“baseline、canonical hint family、家族内部对照、专项消融”四层结构重排。默认将 `dynamic gather-fix` 视为正确的 canonical dynamic 实现，将 old fixed-hint 明确标成带 bug caveat 的历史参考，并把 `max1`、CE scaling、single-hint mixed 与 dual-task 这些后续探索拆成单独 section。

目录

1 Instruments 数据集实验范围 **3**
- 1.1 本文只讨论什么 . . . 3
- 1.2 共享实验背景 . . . 3
- 1.3 本文的默认约定 . . . 3
- 1.4 按什么顺序读 . . . 3

2 主表与 Baseline **4**
- 2.1 主表：Instruments 上当前最重要的 run 地图 . . . 4
- 2.2 SFT 与 rule-only：baseline 在哪里 . . . 5
- 2.3 Canonical dynamic 与 fixed hint：主线大方向 . . . 6

3 Dynamic Sid-Only vs Dynamic Gather-Fix **6**
- 3.1 关键指标 . . . 6
- 3.2 图表 . . . 7
- 3.3 结论 . . . 7

4 Fixed Sid-Only vs Fixed Taskfix **7**
- 4.1 关键指标 . . . 7
- 4.2 图表 . . . 8
- 4.3 结论 . . . 8

5 Ranking Dynamic vs Canonical Dynamic **8**
- 5.1 关键指标 . . . 8
- 5.2 图表 . . . 9
- 5.3 结论 . . . 9

6 错版 Fixed vs Corrected Fixed **10**
6.1 Bug 图 10
6.2 任务级摘要 10
6.3 结论 10

7 Max1 消融 **11**
7.1 实验问题 11
7.2 改动范围 11
7.3 关键指标 11
7.4 图表 12
7.5 结论 13

8 CE Scaling 消融 **13**
8.1 关键指标 13
8.2 图表 14
8.3 结论 14

9 Single-Hint Mixed 消融 **14**
9.1 实验定义 14
9.2 关键指标 15
9.3 图表 15
9.4 结论 16

10 Dual-Task 消融 **16**
10.1 实验定义 16
10.2 关键指标 17
10.3 图表 17
10.4 结论 17

11 结论与下一步 **18**
11.1 当前最稳的主故事 18
11.2 下一步最值得继续补的证据 18

1 Instruments 数据集实验范围

1.1 本文只讨论什么

这份整理稿只讨论 `Instruments-grec` 数据集上的 RL 实验，不把 Games、跨数据集 sweep、reward form 的完整历史演化和更早期的 exploratory runs 一起混进来。当前主线关注的是：

- SFT 与 plain `rule-only` baseline 的位置
- canonical dynamic hint 与 fixed hint family 的相对位置
- dynamic / fixed 家族内部几个关键变体的对照
- 后续几条最值得继续追的消融与扩展：`max1`、CE scaling、single-hint mixed、dual-task

1.2 共享实验背景

- 数据集：`Instruments-grec`
- RL 起点：`Instruments-grec-sft-qwen4B-4-256-dsz0/checkpoint-495`
- 主读法：默认先看 best `NDCG@10`，再看对应的 `HR@50` 和必要时的 peak `HR@50`
- 进度轴：不同 run 的完整 step horizon 不总相同，因此图里统一转成 epoch 时，需要显式写清楚归一化口径

1.3 本文的默认约定

1. `dynamic gather-fix` 被视为当前正确的 canonical dynamic 实现；后文里如果直接写“dynamic”，默认指它。
2. old `fixed hint mixed-single` 只作为带 bug caveat 的历史参考线，不再把它当作方法定义本身。
3. corrected `fixed taskfix sid-only` 被当作当前更干净的 fixed 参考线。

1.4 按什么顺序读

章节	作用	当前内容
主表与 baseline	建立全局地图	Instruments 上的主表、SFT 与 rule-only baseline、canonical dynamic 与 fixed 的位置
Hint 家族内部对照	看清关键 family 差异	dynamic sid-only、ranking dynamic、fixed sid-only，以及 old fixed bug 对 corrected fixed 的影响
专项消融与新探索	跟后续值得继续追的方向	max1、CE scaling、single-hint mixed、dual-task

2 主表与 Baseline

2.1 主表：Instruments 上当前最重要的 run 地图

Group	Variant	Best ckpt	Epoch	NDCG@10	HR@50
Baseline	SFT495	checkpoint-495	–	0.0823	0.1844
Baseline	rule-only rerun	checkpoint-2997	1.802	0.0960	0.1681
Dynamic	dynamic gather-fix	checkpoint-2997	1.802	0.0936	0.1855
Dynamic	dynamic sid-only	checkpoint-2394	1.805	0.0921	0.1830
Dynamic	ranking dynamic	checkpoint-1665	1.001	0.0911	0.1822
Fixed	fixed taskfix	checkpoint-2997	1.802	0.0931	0.1941
Fixed	fixed taskfix sid-only	checkpoint-2652	2.000	0.0945	0.1935
Historical	old fixed mixed-single	checkpoint-3326	2.000	0.0953	0.1938
Ablation	dynamic max1	checkpoint-1332	0.801	0.0934	0.1905
CE	hintce-2	checkpoint-2664	1.602	0.0931	0.1951
CE	hintce-3	checkpoint-1665	1.001	0.0945	0.1985
Hint ablation	single-hint mixed	checkpoint-2664	1.602	0.0948	0.1958
Dual-task	dynamic dual-task	checkpoint-1510	1.003	0.0930	0.1885
Dual-task	fixed dual-task	checkpoint-2718	1.805	0.0939	0.1897

表 1: Instruments 数据集上的主线 run 地图。

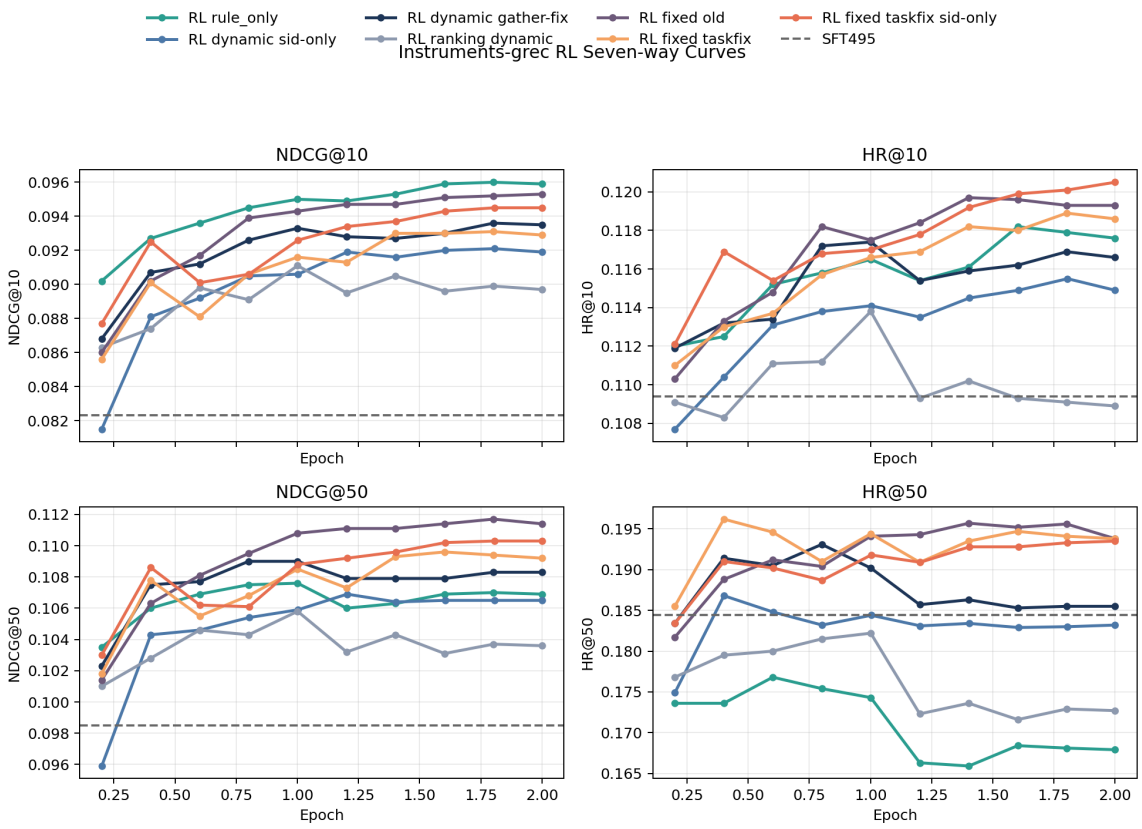

图 1: 主线七线曲线图，用来给后续 section 定位。

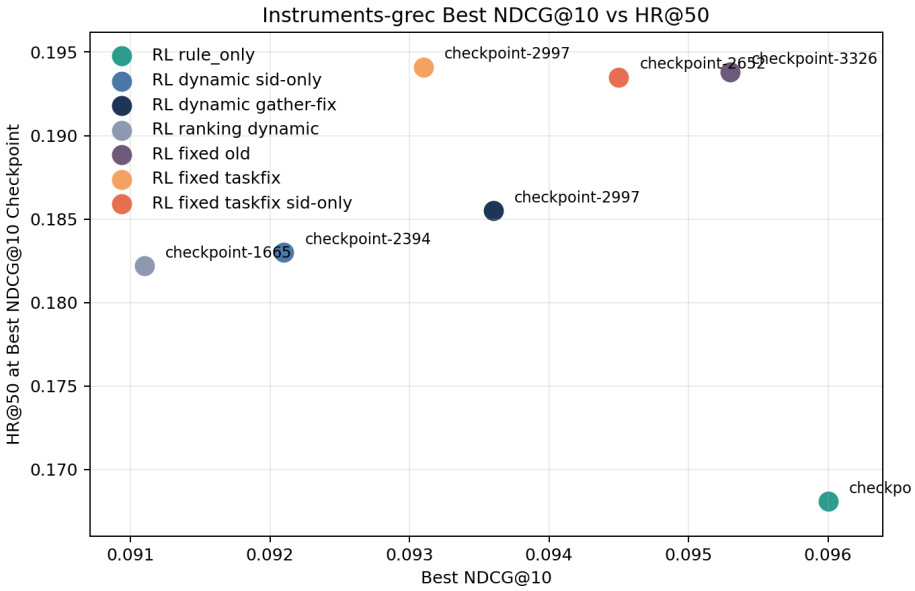

图 2: best NDCG@10 对应的 top-10 / coverage trade-off。

先看这张主表，最重要的定位只有三点：

1. plain `rule-only` 仍然是 top-10 最强 baseline，但 coverage 明显最差。
2. `dynamic gather-fix` 是后文默认使用的 canonical dynamic。
3. clean fixed family、`single-hint mixed`、`hintce-3` 和 `fixed dual-task` 都落在图里的更右上区域，因此它们是后文重点解释的对象。

2.2 SFT 与 rule-only：baseline 在哪里

Variant	Best ckpt	NDCG@10	HR@10	NDCG@50	HR@50
SFT495	checkpoint-495	0.0823	0.1094	0.0985	0.1844
rule-only rerun	checkpoint-2997	0.0960	0.1179	0.1070	0.1681

表 2: SFT 与 plain rule-only baseline。

这一组 baseline 的读法很清楚：

- `rule-only` 相比 SFT，把 `NDCG@10` 从 0.0823 拉到 0.0960，说明 exact reward 确实能把 top-10 打高。
- 但它的 `HR@50` 从 0.1844 掉到 0.1681，说明 plain exact reward 仍然在用 coverage 换 headline top-10。

2.3 Canonical dynamic 与 fixed hint：主线大方向

Variant	Best ckpt	NDCG@10	HR@10	NDCG@50	HR@50
rule-only rerun	checkpoint-2997	0.0960	0.1179	0.1070	0.1681
dynamic gather-fix	checkpoint-2997	0.0936	0.1169	0.1083	0.1855
fixed taskfix sid-only	checkpoint-2652	0.0945	0.1205	0.1103	0.1935

表 3: 主线故事可以先压缩成 baseline、canonical dynamic 和 clean fixed 三条线。

如果只想记住一张最核心的对照表，这张就够了：

- `rule-only` 提供最强的无 hint top-10 baseline。
- `dynamic gather-fix` 是“hint scaffold 有用”的干净证据，它把 coverage 拉回到了 SFT 以上。
- clean `fixed taskfix sid-only` 则进一步把 trade-off 推到了更右上方：相对 canonical dynamic，多了 0.0009 的 `NDCG@10` 和 0.0080 的 `HR@50`。

3 Dynamic Sid-Only vs Dynamic Gather-Fix

3.1 关键指标

Variant	Best ckpt	Epoch	NDCG@10	HR@10	NDCG@50	HR@50
dynamic sid-only	checkpoint-2394	1.805	0.0921	0.1155	0.1065	0.1830
dynamic gather-fix	checkpoint-2997	1.802	0.0936	0.1169	0.1083	0.1855

表 4: dynamic sid-only 与 canonical dynamic gather-fix。

3.2 图表

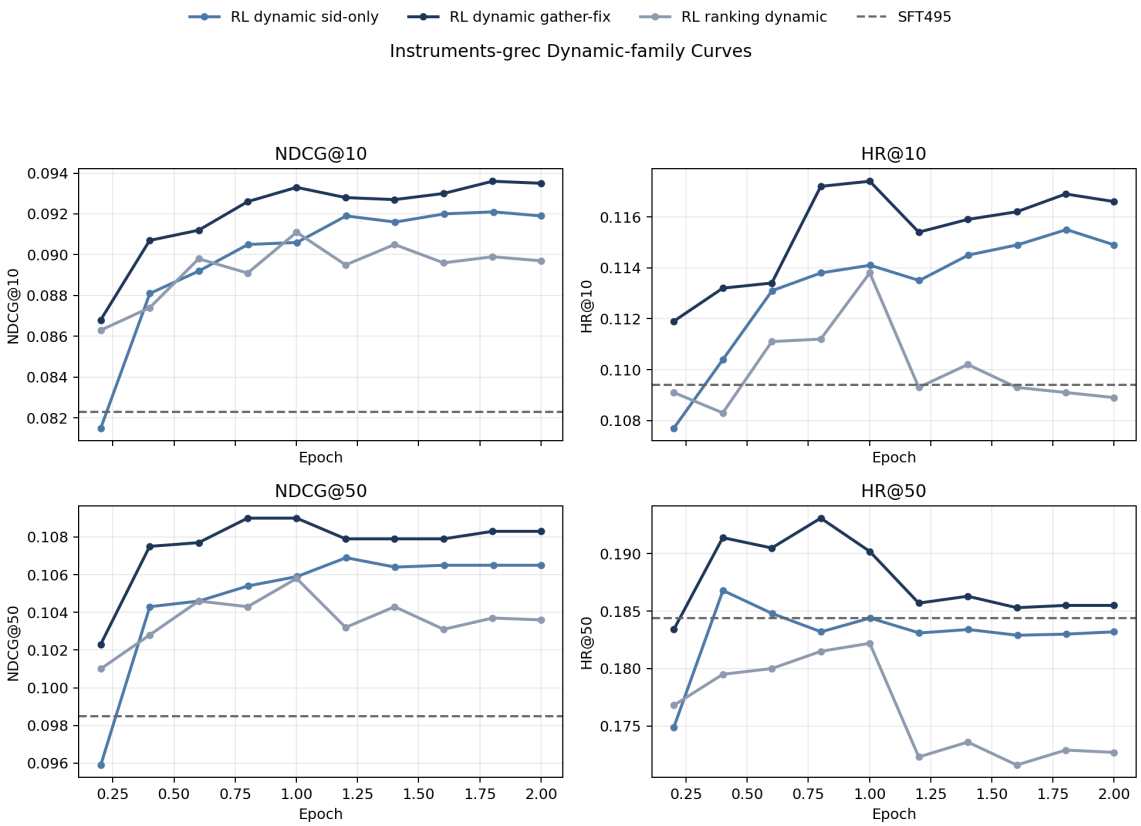

图 3: dynamic family 曲线。

3.3 结论

- `dynamic sid-only` 不是完全失败，但 peak 来得更早，后续没有继续抬高。
- `dynamic gather-fix` 四个主指标同时更强，因此应被视为当前默认的 dynamic 实现。

4 Fixed Sid-Only vs Fixed Taskfix

4.1 关键指标

Variant	Best ckpt	Epoch	NDCG@10	HR@10	NDCG@50	HR@50
fixed taskfix	checkpoint-2997	1.802	0.0931	0.1189	0.1094	0.1941
fixed taskfix sid-only	checkpoint-2652	2.000	0.0945	0.1205	0.1103	0.1935
old fixed mixed-single	checkpoint-3326	2.000	0.0953	0.1193	0.1114	0.1938

表 5: fixed taskfix、fixed taskfix sid-only 与 old fixed 的位置。

4.2 图表

图 4: fixed sid-only 与 fixed taskfix 的对照图。

4.3 结论

- `fixed taskfix sid-only` 主要把 top-10 hit 又往上推了一步，因此它是更合适的 clean fixed reference。
- `fixed taskfix` 本身已经明显强于 plain `rule-only`，说明 task-aware 修复本身就在生效。
- old fixed 仍然可以当历史上界参考，但不应该继续当方法定义。

5 Ranking Dynamic vs Canonical Dynamic

5.1 关键指标

Variant	Best ckpt	Epoch	NDCG@10	HR@10	NDCG@50	HR@50
ranking dynamic	checkpoint-1665	1.001	0.0911	0.1138	0.1058	0.1822
dynamic gather-fix	checkpoint-2997	1.802	0.0936	0.1169	0.1083	0.1855

表 6: ranking dynamic 与 canonical dynamic gather-fix。

5.2 图表

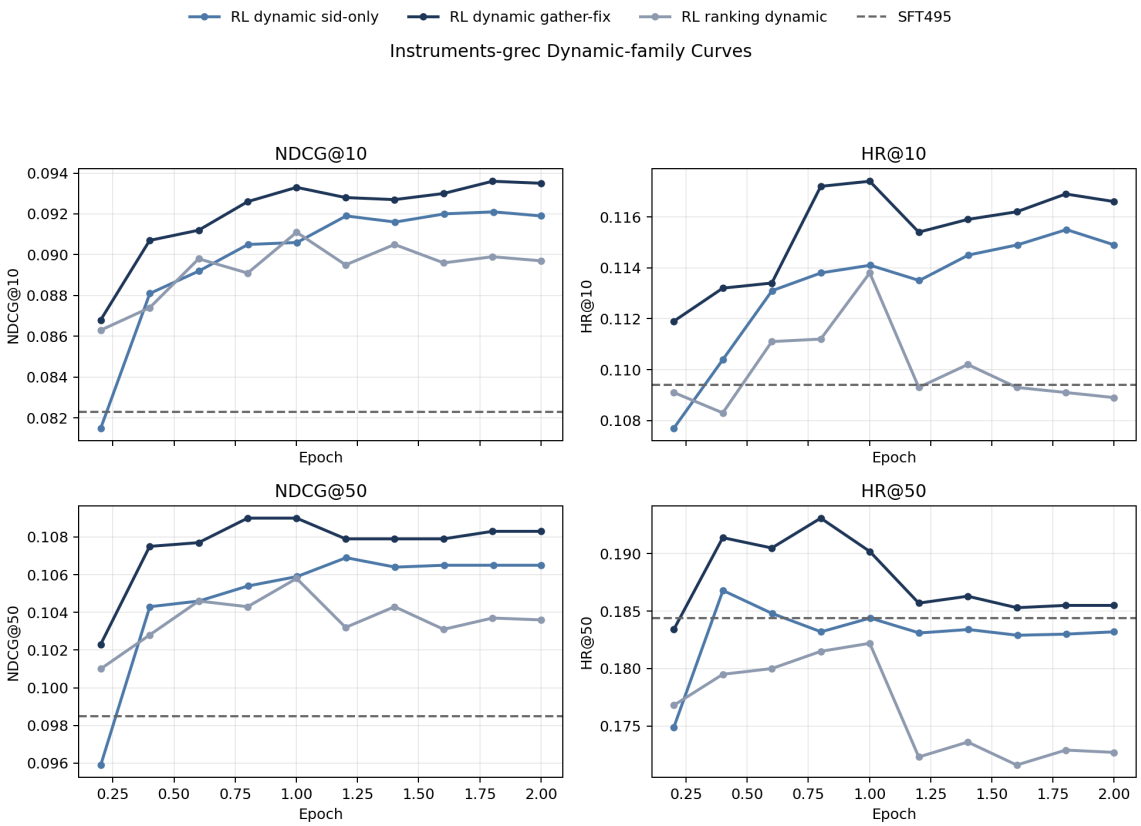

图 5: dynamic family 曲线；ranking dynamic 在同一家族里没有显示出优势。

5.3 结论

- 按 best `NDCG@10` 点比较，`ranking dynamic` 四指标同时落后于 `dynamic gather-fix`。
- 图上也能直接看到它更像“中期见顶，后期失速”的 run，而不是新的主线实现。

6 错版 Fixed vs Corrected Fixed

6.1 Bug 图

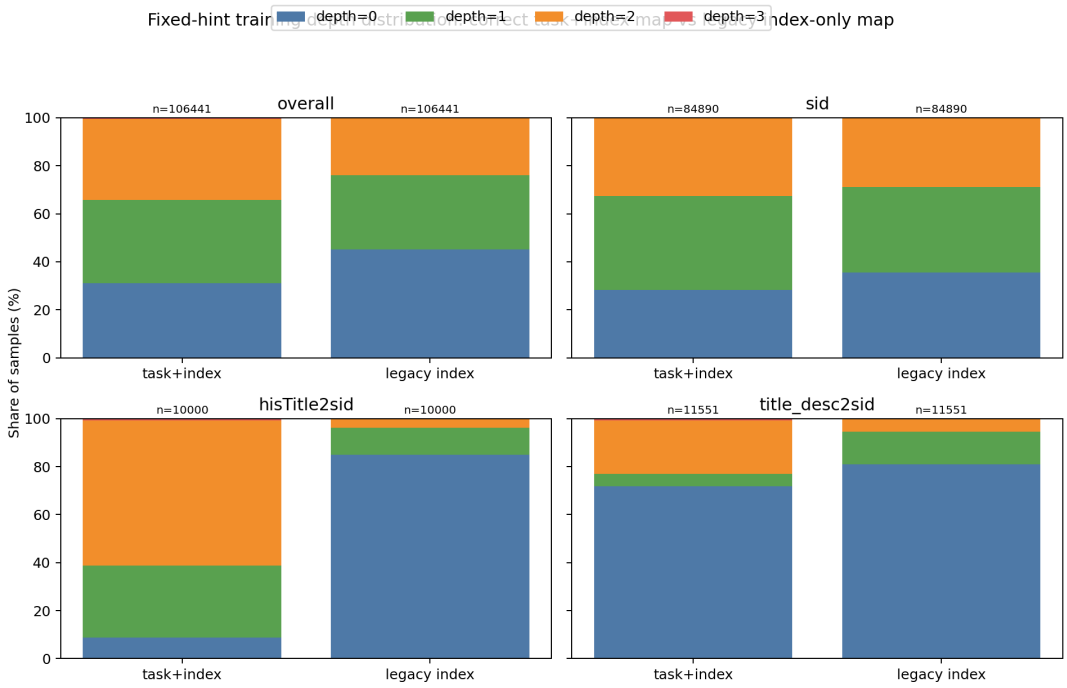

图 6: old fixed 的 bug 会把不同任务的 hint depth 分布系统性压歪。

6.2 任务级摘要

Task	Changed rate	Avg depth correct	Avg depth buggy	主效应
`task1_sid_sft`	7.64%	1.048	0.938	只被轻微压浅
`task4_hisTitle2sid`	82.35%	1.533	0.188	hardest task 几乎被压成 depth-0
`task5_title_desc2sid`	19.41%	0.519	0.245	一部分 depth-2 被压回 0/1

表 7: old fixed 的 bug 不是“hint 更准”，而是把任务分布系统性压浅。

6.3 结论

- old fixed 的表面优势，不是来自更正确的 hint map，而是因为 hardest task 被系统性少给 hint。
- 因此它更像一个带偏置的历史现象学上界，而不是应该继续复用的方法定义。
- 这也是为什么本文后文在需要 fixed reference 时，默认优先引用 corrected `fixed taskfix sid-only`。

7 Max1 消融

7.1 实验问题

这一组实验只改一件事：把 dynamic hint 的 online budget 从 `dynamic_hint_max_depth=3` 收紧到 `1`。因此它回答的问题也很集中：

> 如果只允许 dynamic hint 最多暴露 1 个 oracle token，而不改 trainer 逻辑、不丢 no-hit 样本，最终的 eval trade-off 会落在什么位置。

7.2 改动范围

维度	baseline	max1 实验	备注
reward mode	rule-only	rule-only	不变
num beams	16	16	不变
dataset variant	Instruments-grec 主线数据	相同	不变
trainer 收口逻辑	当前 dynamic trainer	相同	不变
样本筛除	不丢 no-hit 样本	不丢	不变
hint budget	max depth 3	max depth 1	唯一改动

表 8: max1 消融的唯一改动是 online hint budget。

7.3 关键指标

Variant	Best ckpt	Epoch	NDCG@10	HR@50
rule-only rerun	checkpoint-2997	1.802	0.0960	0.1681
dynamic gather-fix	checkpoint-2997	1.802	0.0936	0.1855
dynamic max1	checkpoint-1332	0.801	0.0934	0.1905
fixed taskfix sid-only	checkpoint-2652	2.000	0.0945	0.1935

表 9: max1 的位置：更像 early-stop dynamic candidate，而不是新的默认线。

7.4 图表

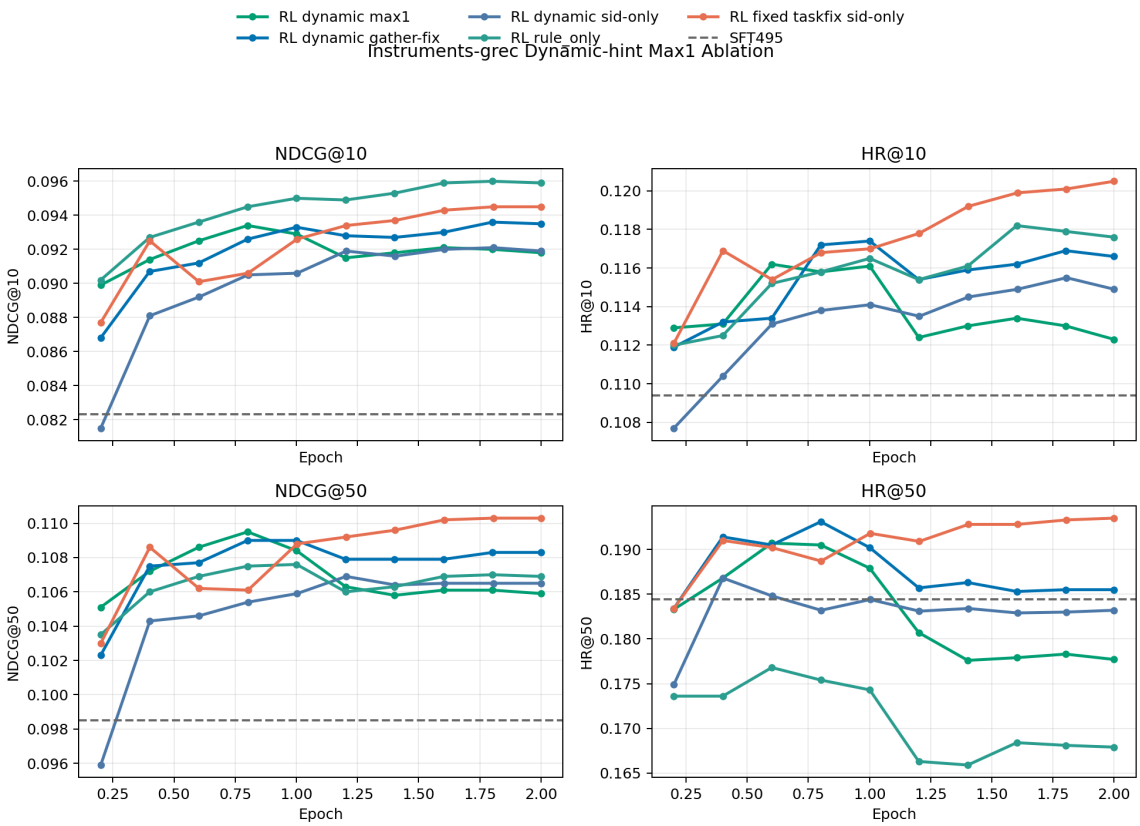

图 7: max1 ablation 曲线。

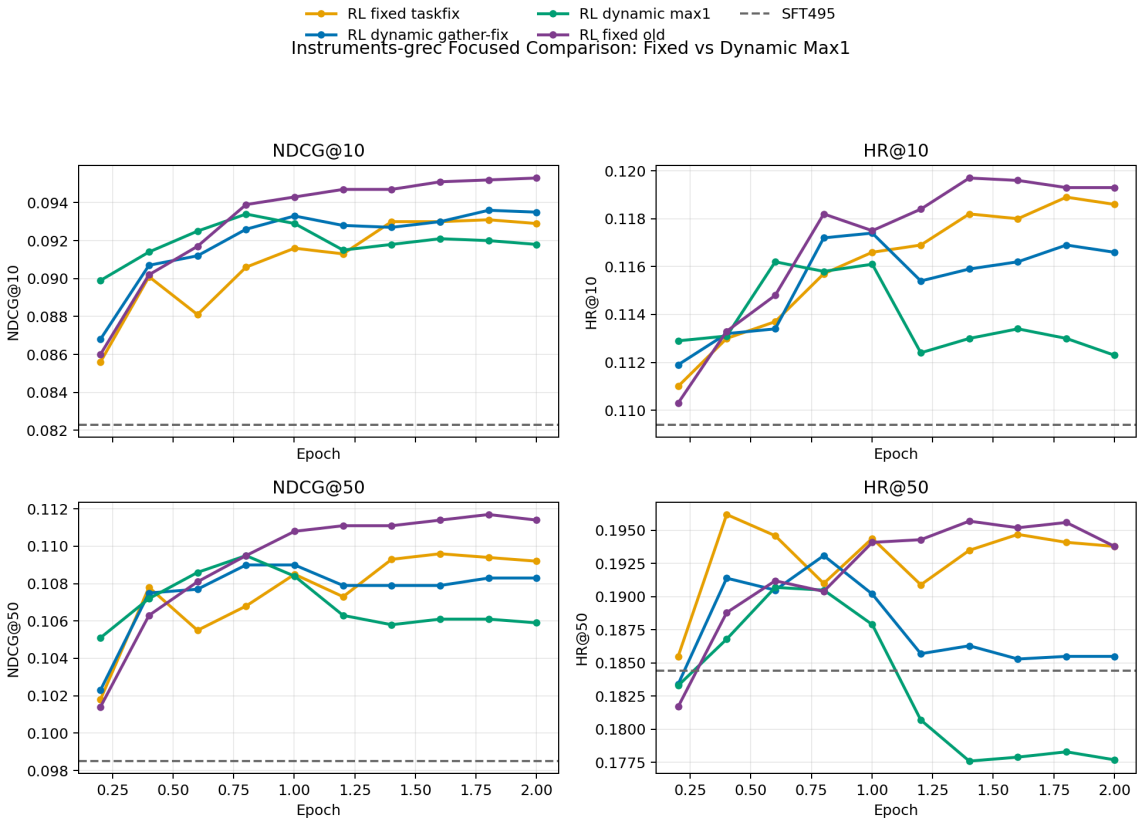

图 8: max1 与 dynamic/fixed 参考线的 four-way comparison。

7.5 结论

- `max1` 不是退化成 `rule-only`，因为它保住了明显更高的 coverage。
- 它也不是被 `gather-fix` 全程支配，因为早中段确实能给出更好的 trade-off。
- 但完整轨迹已经说明它的优势主要停在前中段，因此更准确的定位仍然是 early-stop 候选，而不是新的 long-run default。

8 CE Scaling 消融

8.1 关键指标

Variant	Best ckpt	Epoch	NDCG@10	HR@50	备注
fixed taskfix	checkpoint-2997	1.802	0.0931	0.1941	non-CE 参考线
hintce-2	checkpoint-2664	1.602	0.0931	0.1951	当前更稳的 CE 候选
hintce-3	checkpoint-1665	1.001	0.0945	0.1985	CE 相对倍率 0.005，当前最强中段峰值

表 10: CE scaling 消融。

8.2 图表

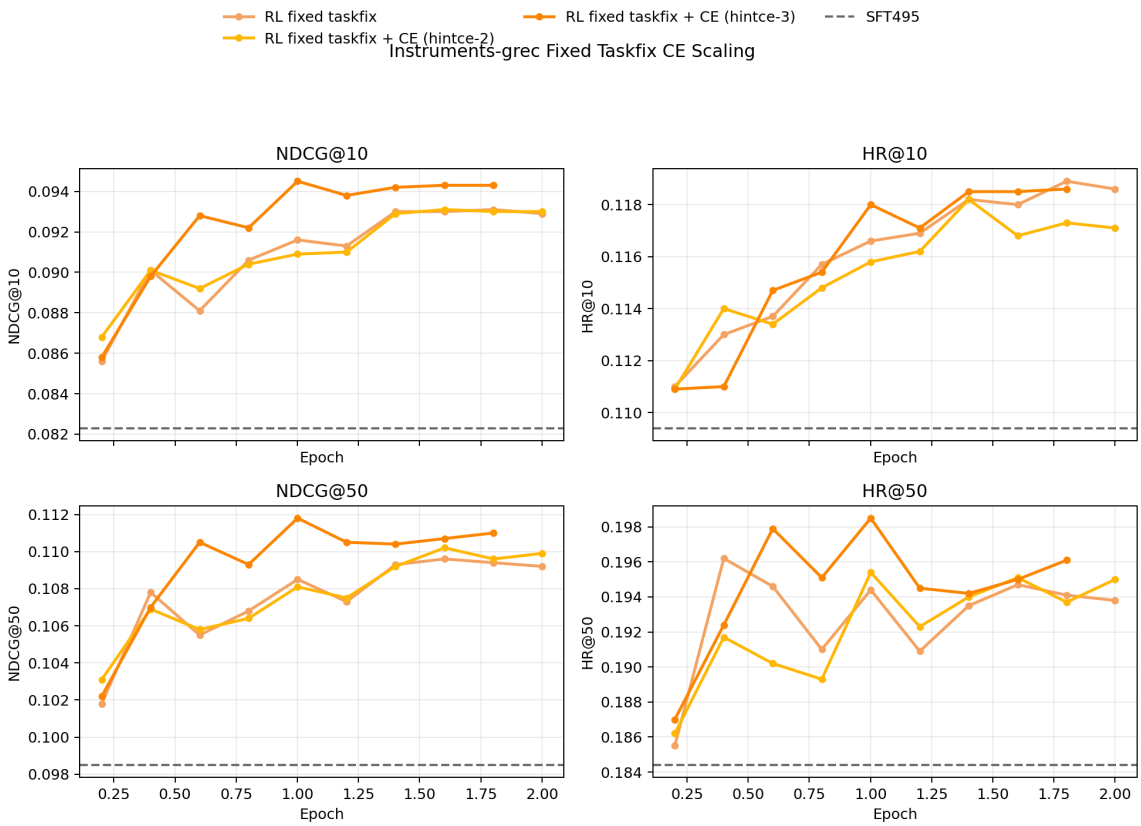

图 9: CE scaling 曲线，包含 `hintce-3`。

8.3 结论

- full non-CE 仍然是当前 fixed family 的干净参考线。
- `hintce-2` 把 CE 从 early readout 拉成了一个完整轨迹上的更稳候选。
- `hintce-3` 对应更高的 CE 相对倍率 0.005，并且已经把中段 best 点推到 `0.0945 / 0.1985`；真正还缺的是最后一段 terminal readout。

9 Single-Hint Mixed 消融

9.1 实验定义

这条线不是“只训练 `task1`”，而是 mixed 三任务仍然一起训练，只是 fixed hint 只注入到 `task1_sid_sft`，其余任务继续按 zero-hint 路径走。

9.2 关键指标

Variant	Best ckpt	Epoch	NDCG@10	HR@50
fixed taskfix	checkpoint-2997	1.802	0.0931	0.1941
fixed taskfix sid-only	checkpoint-2652	2.000	0.0945	0.1935
old fixed mixed-single	checkpoint-3326	2.000	0.0953	0.1938
single-hint mixed	checkpoint-2664	1.602	0.0948	0.1958

表 11: single-hint mixed 是当前最强的 partial-hint 候选。

9.3 图表

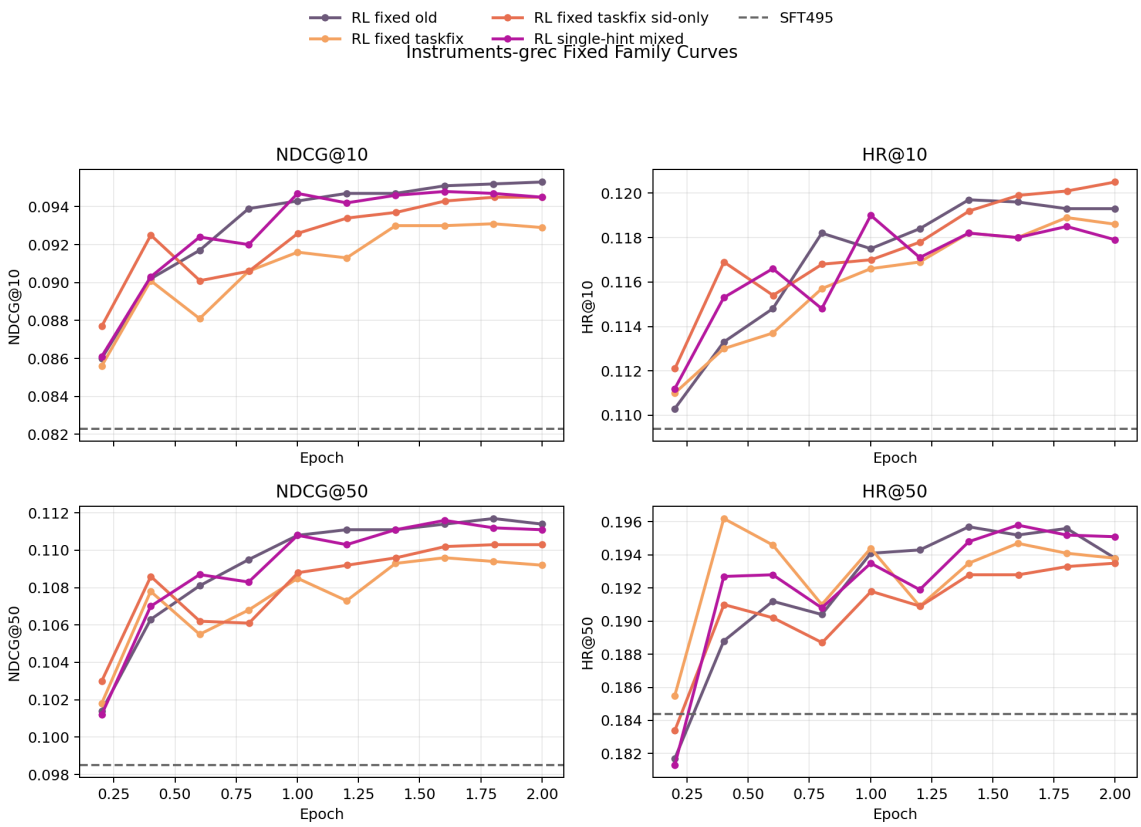

图 10: single-hint mixed vs fixed family。

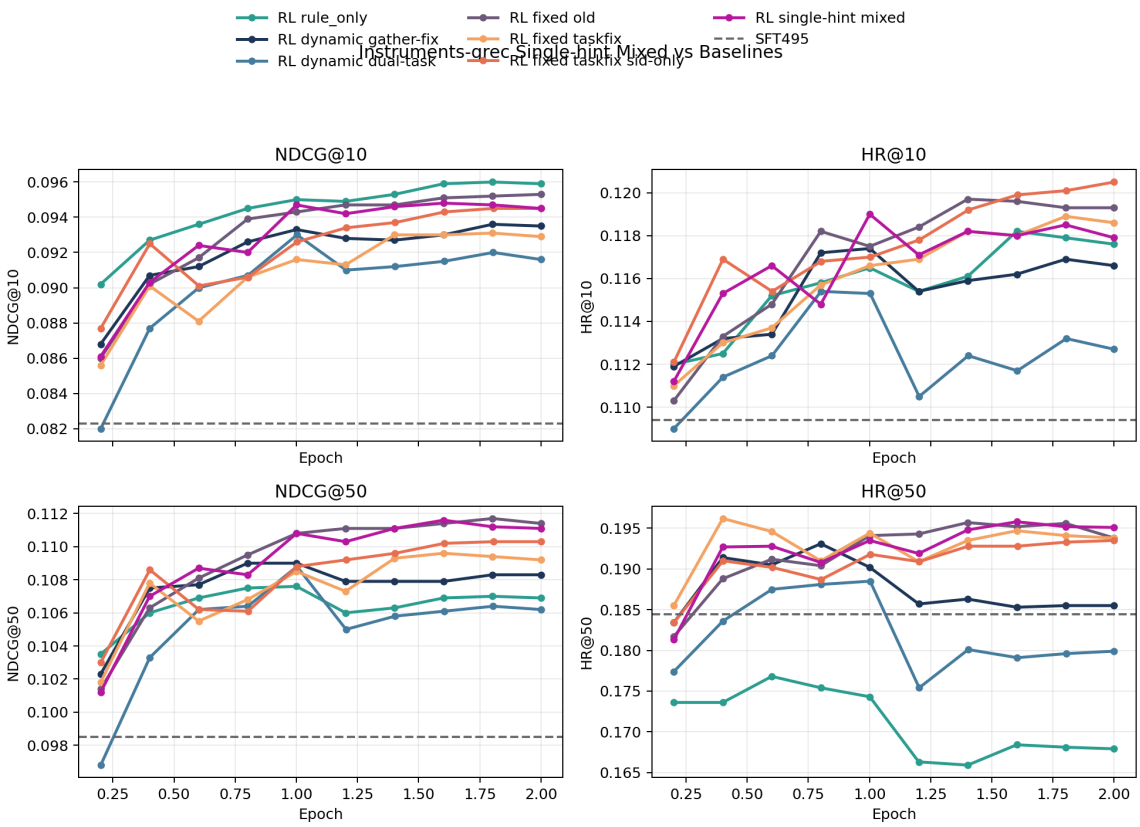

图 11: single-hint mixed vs baselines。

9.4 结论

- 这条线不是“只训练 task1”,而是 mixed 三任务仍然训练,只是 fixed hint 只注入到 `task1_sid_sft`。
- 它当前 best 点已经同时超过 corrected `fixed taskfix sid-only` 的 `NDCG@10` 和 `HR@50`。
- 因此后续更值得解释的问题不是“它有没有信号”，而是它为什么能在完整尾段维持住 fixed family 前沿水平。

10 Dual-Task 消融

10.1 实验定义

这一组实验只保留 `task1 + task5`，因此要同时看 dynamic 与 fixed 两条 dual-task 线，并把它们放回 canonical dynamic 与 clean fixed reference 的上下文里读。

10.2 关键指标

Variant	Best ckpt	Epoch / aligned epoch	NDCG@10	HR@50
dynamic gather-fix	checkpoint-2997	1.802	0.0936	0.1855
dynamic dual-task	checkpoint-1510	1.003 / 1.861	0.0930	0.1885
fixed dual-task	checkpoint-2718	1.805 / 1.972	0.0939	0.1897
fixed taskfix sid-only	checkpoint-2652	2.000	0.0945	0.1935

表 12: dual-task family 与 canonical dynamic / clean fixed reference 的位置。

10.3 图表

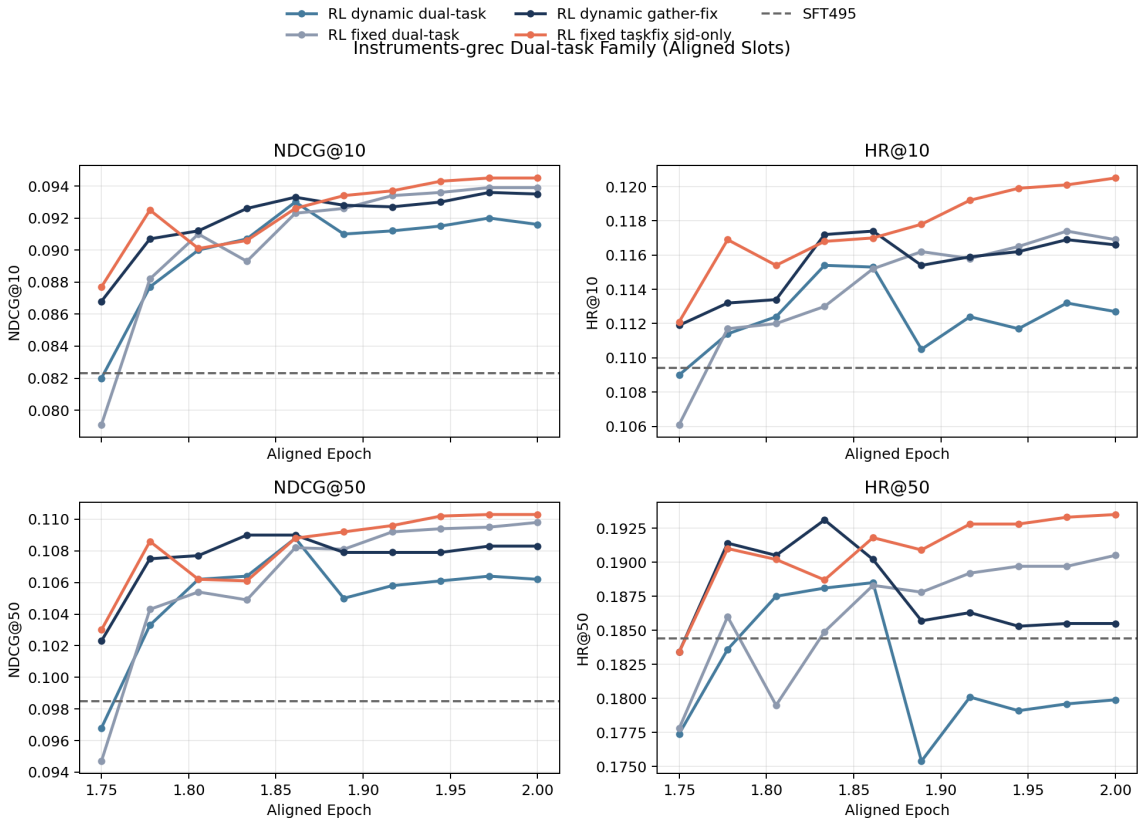

图 12: dual-task family aligned curves。

10.4 结论

- `dynamic dual-task` 已经进入可比较状态，但还没有超过 canonical `dynamic gather-fix`。
- `fixed dual-task` 已经整体强于 `dynamic dual-task`，因此 dual-task family 内部也复现了“fixed 比 dynamic 更稳”的方向。

- 但它离 clean fixed 主线仍然有明显差距，所以当前更准确的定位是：dual-task 是一条值得继续跟的 filtered setting，而不是已经改写主线排序。

11 结论与下一步

11.1 当前最稳的主故事

1. plain `rule-only` 仍然是当前 top-10 最强的无 hint baseline，但 coverage 损失很明确，因此不适合直接当 balanced 主线。
2. `dynamic gather-fix` 应被视为当前 canonical dynamic 实现；`dynamic sid-only` 和 `ranking dynamic` 都还没有超过它。
3. clean fixed family 仍然是当前最强的 balanced 主候选；其中 corrected `fixed taskfix sid-only` 是更干净的 fixed 参考，而 old fixed 只能当 historical reference。
4. 在后续探索里，`max1` 更像 early-stop dynamic candidate；`hintce-3`、`single-hint mixed` 和 `fixed dual-task` 则分别对应 CE scaling、partial-hint 和 task-filtered 三条新的探索方向。

11.2 下一步最值得继续补的证据

- 补 `hintce-3` 的最后一段 terminal checkpoint，确认它是不是稳态新上界，而不只是中段强峰值。
- 继续跟 `single-hint mixed` 的尾段平台，并解释为什么它能在完整 2 epoch 维持住 fixed family 前沿。
- 继续跟 `dynamic dual-task` 与 `fixed dual-task` 的终段 readout，确认 dual-task family 的稳定排序。
- 如果后面要把这份稿件扩成更正式的研究报告，建议继续沿用“一个实验主题一个子文件”的结构，而不是回到按日期拼接的 note 模式。